为什么GT10难以超越：项目现状、机制证据与改进方向

2026-09-22，按用户要求研究至17:00。本轮是只读历史核算、源码/理论审查和一手文献调研，不是新的性能实验。默认仍为 **WebVid GT10-soft-t1、Yandex GT10-hard，生产E99**；E103仍是最近完整五数据集比较。

核心判断：GT10的强项是一个组合——GT引导的真实入口池、把大量查询监督压缩成静态画像、与画像匹配且便宜的小图路由。后继面对的是较小、易抵消、跨预算变化的残差，还要支付额外在线费用。现有证据不支持“十目标画像本身解释了全部系统增益”，也不支持“GT10已经达到理论最优”。

阅读入口：理论与反例 · 15项一手文献核对 · 按优先级排列的改进方向 · 数字核验。

1. 先区分三件常被混在一起的事

要回答的问题	合适对照	当前结论
GT10整个系统为什么胜固定NSG入口?	同一底图/内核下，固定入口对QGT候选与画像路由	自适应选入口有收益，但相当一部分质量收益在不使用GT10画像的UnitHub控制中已出现。
从GT1改为GT10，十目标到底增加了什么?	同H、同监督样本、hard对hard，再分离路由近似	支持更分散、画像改变明显；最终增益小且依数据/预算，ESS及目标细节的因果贡献尚未完全分开。
为什么后继模型难胜当前默认?	当前默认与冻结候选的真实K1/K100完整Recall–QPS	动作机会、可迁移信息、损伤抵消、预算错配、在线费用同时限制；失败不是一个统一原因。

“几十次实验”包含同一分支的诊断、控制、修复和完整验收，并非几十个独立的新范式。历史K10开发指标也不能直接替代今天的K1/K100。结论应按作用机制和证据强度整理，而不是累计负实验数量。

2. 当前性能到底强到哪里

下表由E103原800点指标重算，选择 **实测Recall达到90%的最快已测配置**。这不是两方法实际Recall完全相等的精确匹配，也不是显著性结论；所有NSG入口方法共用span+batch4内核。Web/Y使用当前默认，其他集展示GT10-soft-t1，不为此更改其默认。

数据	K	GT10实测Recall / L	GT10 QPS	NSG QPS	相对NSG
WebVid	1	90.7500% / 800	520.79	416.68	+24.99%
WebVid	100	90.6868% / 1250	340.46	337.80	+0.79%
Yandex	1	91.0500% / 128	2406.16	2194.80	+9.63%
Yandex	100	90.9805% / 256	1241.64	1160.90	+6.96%
Deep	1 / 100	94.1300% / 32；92.6021% / 100	8804.34 / 3503.61	7497.14 / 3298.49	+17.44% / +6.22%
SIFT	1 / 100	95.9100% / 32；94.0603% / 100	7661.98 / 3015.93	7227.79 / 2922.68	+6.01% / +3.19%
GIST	1 / 100	92.2000% / 96；91.6700% / 256	1229.41 / 550.73	1220.23 / 550.43	+0.75% / +0.05%

所以“GT10很强”不是每个K/数据集都有巨大优势。Web K1很突出，Web K100在这个门槛只有小优势，GIST接近持平且其他门槛会落后。GT10家族在22/25个可达门槛格子描述性最快，也不等于某个统一模型显著支配全部方法。重算表 · E103原报告。

还要扣除实现混杂：E101–E103发现span+batch4本身会明显加速NSG；例如E102 NSG四点自身平均QPS提升18.58%–27.28%。今天讨论方法优势必须使用统一优化内核，不能把旧内核到新内核的提升算作GT10机制。E102。

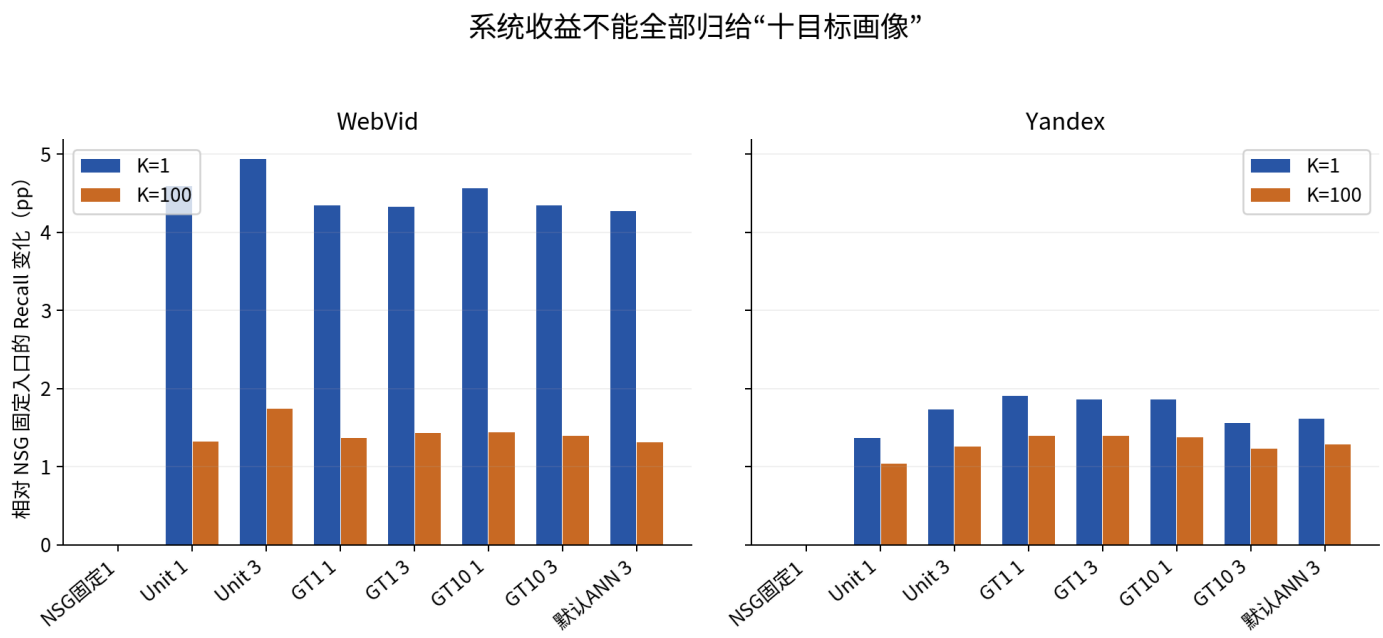
最近后继结果：E118 GraphCost在20个匹配预算点逐query命中等于默认但QPS更低；E119强评分器拟合内正收益没有迁移；E120/record125 TargetKNN在12个匹配点召回均值均正，但Web完整QPS下降17.58%–26.96%，Y下降27.88%–54.06%。后者是“有质量增益但不划算”，不能写成“完全没学到东西”。

3. GT10好在哪里：证据与推断分开

3.1 一个已经使用GT的好入口池

QGT先用独立5K query做球面聚类，按簇中心附近的query依次扫描其GT100，选全局未使用的真实base ID，形成815/821个候选。它不是随意挑点、不是GT频次投票，也不是有近似保证的set cover。**UnitHub依然使用这个已由GT选好的H，因此不是完全无监督基线。**

E107同批L128：UnitHub1相对NSG在Web K1/K100已有+4.5898/+1.3228pp，默认GT10为+4.2725/+1.3127pp；Y分别为+1.3672/+1.0408pp与+1.6113/+1.2871pp。这说明画像以外的自适应初始化已经很强。但UnitHub1是精确全H选点，没有完整路由费用，不能据此直接换默认，也不能把它当QGT相对随机H的因果份额。



E107/E120 同批 L128；Unit/GT1/GT10 1/3 为精确路由，默认为真实 ANN；Unit 仍使用 QGT 已选出的 H。

3.2 静态画像把query分布信息提前算完

GT10把每条训练query的前10个GT目标分配给已有hub，将质量平均，再对单位query加权求和并归一化：

`p_h = normalize(unit(real_hub_h) + Σ_i a_ih × unit(query_i))`。

这个方向是固定权重下线性亲和目标的精确最优解。训练20K query的监督被压缩为H个向量，线上不读GT、不运行query MLP、不枚举完整动作组合；一次小HNSW取3个真实入口，交给原NSG。它保持了很强的计算经济性。离线GT、QGT构建和画像成本不能因为无梯度就记为零；当前缺失的GT-inclusive全链成本仍应保留缺口。

从GT1到GT10-hard，E27的每query平均参与hub数为Web5.993、Y4.571，hub ESS中位数由16→67.361、22→60.082；约78.10%/63.65%的三入口发生改变，但最终命中变化小。十目标可以提供更平滑、覆盖更广的监督，这是合理机制；尚不能宣称这是最终收益的唯一原因。shuffle和E106组均值控制没有完成这种因果识别。E27 · E106。

E106同H、精确top3、L128的直接GT10对GT1比较也没有统一正方向：Web soft的K1/K100为+0.0244/−0.0435pp，Y hard为−0.2930/−0.1680pp。这些局部均值不推翻GT10完整系统的地位，却要求把“十目标的增量作用”与“整个系统为什么好”严格分开。

3.3 好的不只是评分向量，还有它诱导的小图

E108：GT10小图对其自身精确top3的成员召回为Web93.953%、Y97.323%，UnitHub小图为81.250%/91.748%；同时平均路由NDC为112.26/107.01，低于UnitHub的165.17/215.71。这里的“成员召回”是小图路由精度，不是最终R1/R100。

E115把评分P/U和小图状态GP/GU交叉，固定U评分时换成GP仍省NDC。进一步计数表明，Y的base展开**11.546→12.735，反而增加**，邻边扫描却241.854→160.630；GP/GU第0层平均出度为11.029/20.593。Web方向相同。因此更准确的解释是“处理更少邻边和新节点”，而非“路径一定更短”。层级、访问节点和评分仍交互，不能全归因静态度，也不能由此要求继续删边。E115原报告 · 工作量恒等式。

这种路由优势的绝对规模也有边界。E27历史Web L128分项中，路由只占总wall约1.49%，GT1→GT10的路由节省0.367微秒，仅为原总时间约0.079%，不能独自解释该点0.890%的QPS增幅。分项独立计时不能相加做精确归因；在更高预算，主搜索往往更占主导。应强调GT10的路由足够便宜且可索引，避免把总吞吐优势全部归给小图。原分项证据。

3.4 后继必须胜过一个很便宜的默认，不能只胜画像代理

E36总NDC仅增约0.3%–0.4%，完整QPS却降8%–9%，选择器的非距离费用是真实成本。今天KNN召回全正而QPS全负再次验证了这一点。E118即使回退到完全相同命中，也要付新决策过程的费用。GT10的低在线成本是一项直接可测的优势。

4. 本轮新增核算：剩余空间长什么样

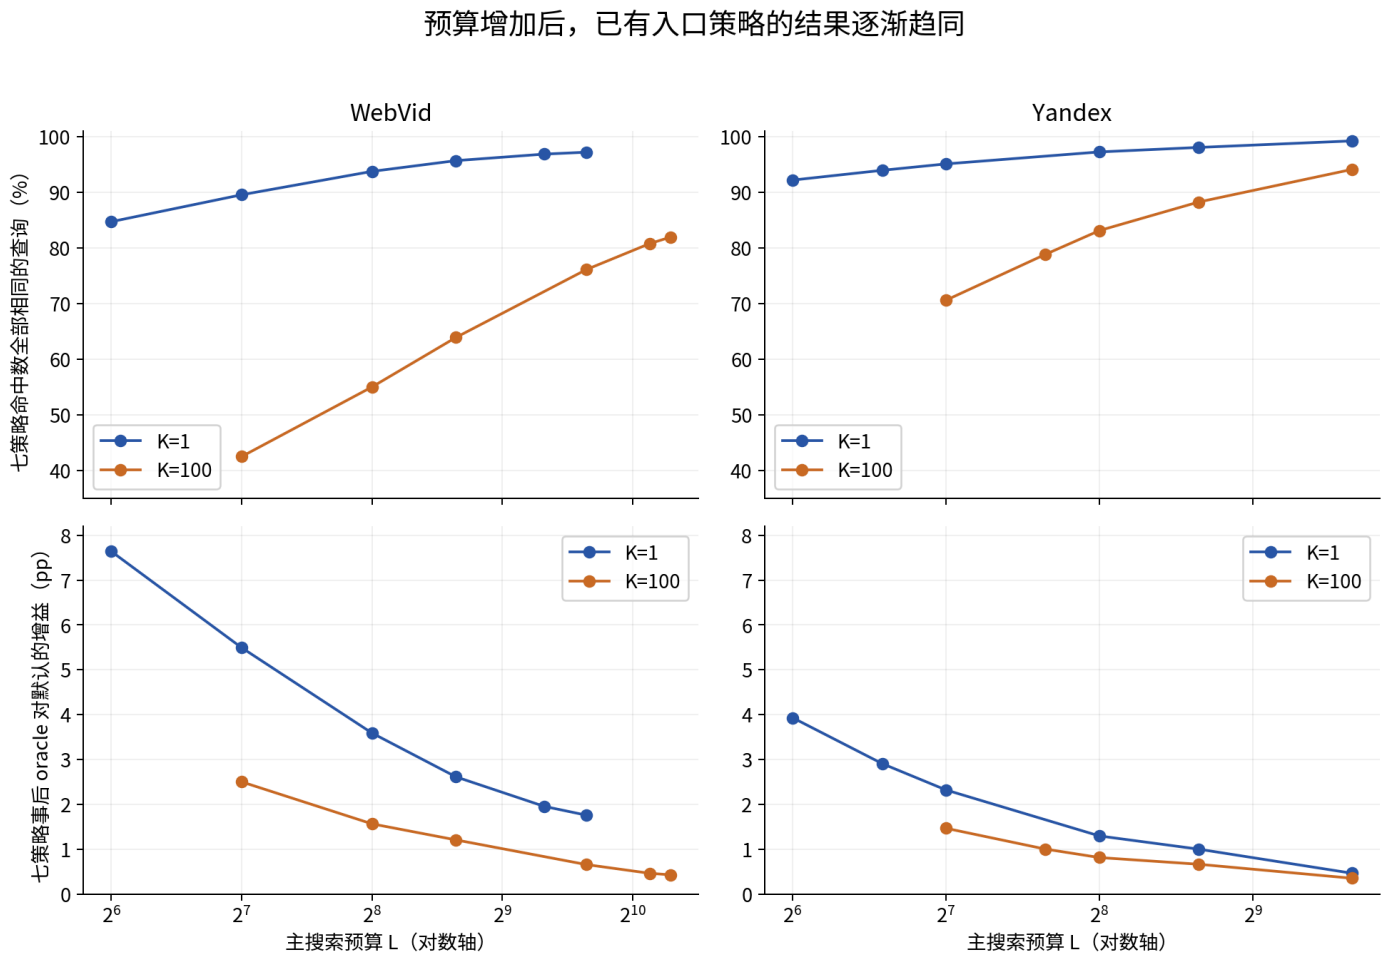
本轮读取旧输出，不新增搜索。E107/E120组是各4096条已曝光E105来源query；E118全H组是另一批4096条历史fit query。**两组不相减、不拼接为因果分解。** 以下同批全H/四动作比较才可相减。每个K分别按真实指标计算。

4.1 原有策略越来越多地给出相同命中数

七策略为UnitHub1/3、GT1 1/3、GT10 1/3及实际DefaultANN，不含NSG固定入口。每个query的事后oracle取七者最好，选择免费。完整23个K/L点见数据。

数据/K/预算	七策略命中数全相同的query	oracle对默认增益	oracle能补回的默认缺失命中质量
Web K1 L128	89.55%	5.4932pp	22.26%
Web K1 L800	97.19%	1.7578pp	16.25%
Web K100 L128	42.55%	2.5007pp	7.26%
Web K100 L1250	81.93%	0.4272pp	4.54%
Y K1 L128	95.09%	2.3193pp	24.74%
Y K1 L800	99.22%	0.4639pp	22.89%
Y K100 L128	70.63%	1.4648pp	9.04%
Y K100 L256	83.13%	0.8125pp	9.07%

Web K1 L800在这批只有89.1846% Recall，不能称R90实测点。K100“命中数相同”不代表返回成员相同；任何K也不代表路径或时间相同。这些百分比是有限策略族的经验响应平台，不是全H上界。



E107/E120 已曝光 4096 query/集；七策略不含 NSG 固定入口。命中数相同不代表返回成员或时间相同。

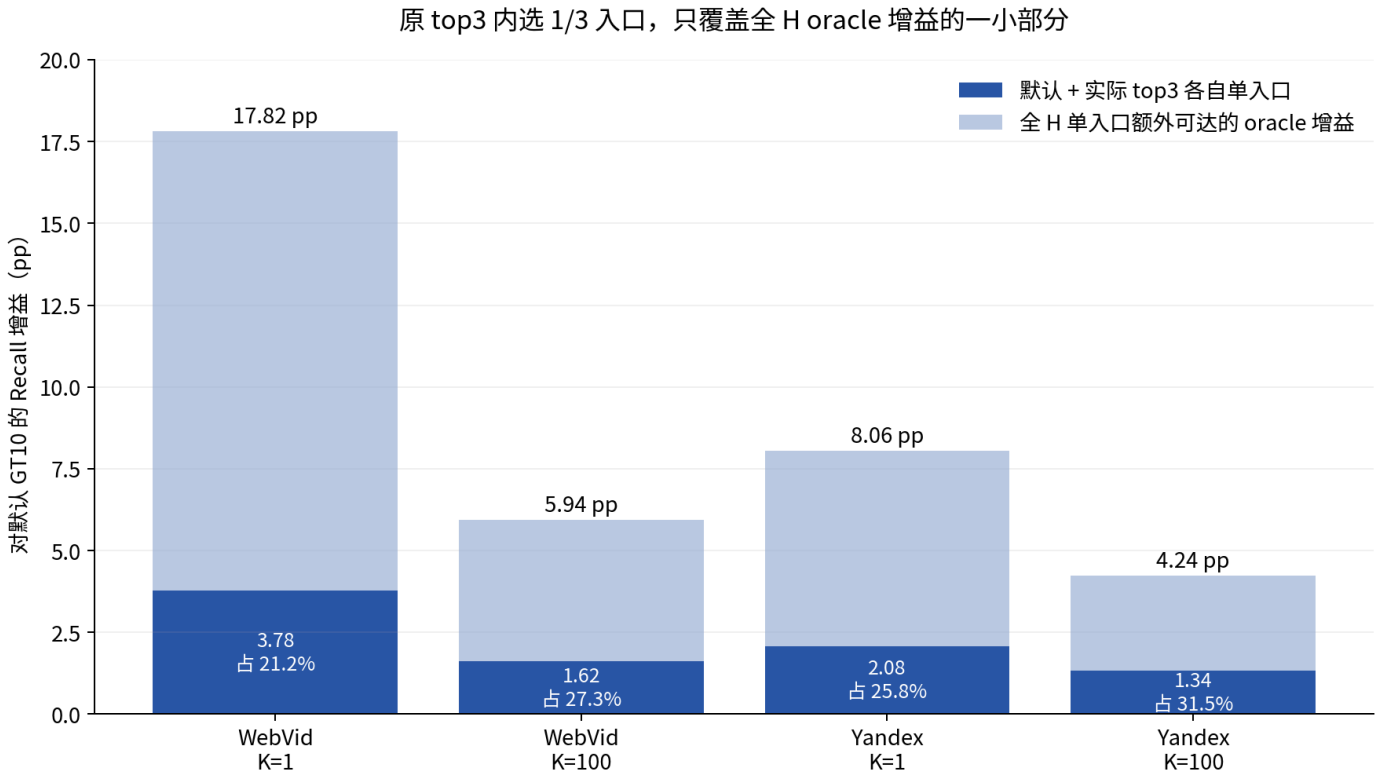
在L128，仅把GT10从ANN改成精确画像top3：Web有580条入口不同，K1只救回21/损伤18；Y有270条入口不同，只救回6/损伤8。改变入口的query中分别93.28%/94.81%命中不变。**更准地实现同一个代理排序，未必产生值得付费的搜索改进。**完整逐方法配对。

4.2 全H空间仍大，但原top3仅触及小部分

同一E118 fit、L128，以默认三入口作回退，比较所有H个单入口，及仅原实际top3各自单入口。两个oracle都查看真实返回，选择免费，两个K分别选择；不代表存在一个策略同时实现它们。

数据/K	全H单入口+默认 oracle增益	原top3各自单入口+默认 oracle增益	后者覆盖前者
Web / 1	17.8223pp	3.7842pp	21.23%
Web / 100	5.9446pp	1.6228pp	27.30%
Y / 1	8.0566pp	2.0752pp	25.76%
Y / 100	4.2410pp	1.3379pp	31.55%

Web默认K1失败935条，全H可救730条，原top3 singles只可救155条；Y为345、330、85条。于是不能只根据原top3门控失败就说“入口已无空间”。同时，原top3内反复做更强分类，也不会触及其余机会。同批分解。

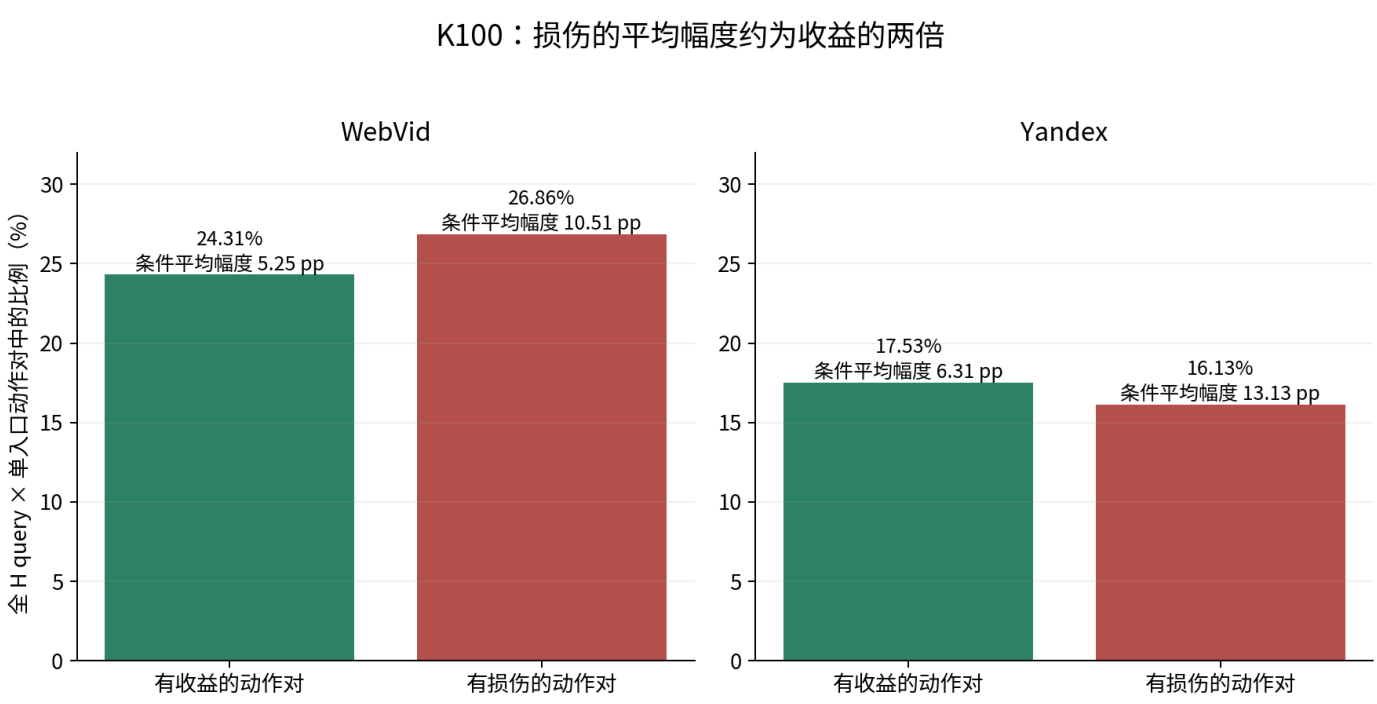


同一批 E118 fit 4096 query/集、L128；两个 K 分别事后择优，选择免费。不是可部署收益或全动作上界。

4.3 有空间不代表一个普通入口就能捡到

在至少一个单hub能救回的query中，能救回的hub比例中位数仅Web2.33%、Y9.93%。均匀随机换一个H中的单入口，K1总体反而下降3.9813/1.0352pp。甚至假设免费知道默认是否会错、只在失败时随机选单入口，也只获得2.1289/1.7956pp，远低于逐query全H oracle。后者只是区分失败检测与动作识别的诊断，不是新的部署策略或普遍上界。

K100更能说明“看胜率会出错”：Web有收益动作对平均增加该query的5.25pp Recall，有损伤动作对平均损失10.51pp；Y为6.31/13.13pp。Y正动作对占17.53%，负动作对占16.13%，**正例更多但均匀换入口的净Recall仍下降1.0116pp**。必须学的是带幅度的净效用。完整分布。



E118 fit，L128；条件幅度是单个 query 的 Recall 变化，非总体增益。未画命中数不变的动作对。

5. 为什么几十次后继没有形成替换

障碍	关键实证	应有结论
代理与真实搜索不对齐	E109完美覆盖/目标均值在Web未改善，Y有局部正值	先检查代理到搜索的桥梁；不能默认更强回归必有收益。
联合入口不是独立覆盖并集	E107 GT10 1→3在18项中17个均值为负；E110首展开干预只修复部分且未胜强单入口	入口间存在有限池竞争；别用单入口收益相加训练三入口策略。
大范围改入口但净效应抵消	E105入口改变97%以上；Web K1救回125/损伤126，Y63/63	“确实改变了结果”不等于提高平均质量，也不是完全空动作。
可拟合不等于可迁移	E119 GBDT/TabM拟合U正、query-out U负；E113绝大多数精确比较对只被一条query使用	共享信息、样本支持与选择误差尚未解决；不是所有深模型不可能。
学习/评价工作点错配	E120低预算选择在目标K100预算仅保留43.31%/70.49%的七策略oracle收益	标签必须服务实际K/L；目标预算KNN又未胜固定/打乱控制，修对齐仍不够。
在线费用吃掉小收益	E36、E118、record125的完整wall	必须同时过召回和完整时间；NDC不是QPS。
统计分辨率与选择曝光	E105 Web K1配对标准误约0.387pp；许多数据/动作反复用于开发	CI跨0不能证明真实效果恰为0；历史小正值也不能直接当新测试收益。

旧RL/画像/多模态分支也不能简单概括为“所有点都差”：E32真实收益目标有更强fit与小幅开发信号，E36有Y局部信号，E94有相对compact的质量修复；它们均未形成稳定默认前沿替换。具体原件见E32、E36、E37、E94、E95停止。

先前原生/评分/输入身份/线程审计已排除了多项实验错误；本轮又独立重写算术，核验6,709,248个query×动作的K1标签与K100位图计数，以及23个有限策略点。Web同向量不同ID的已知tie只影响特定K1均值0.0244pp，不能解释大量后继失败；不删除该query或重写原指标。

6. 哪些理论已经成立，哪些仍是空缺

已经成立：固定权重下的球面亲和闭式最优解；IID条件下的均值方差和方向误差界；有限比较程序的局部行为稳定条件；Recall的救回−损伤恒等式；候选遗漏、信息不足、估计遗憾的非负分解；完整时间的费用约束。它们有助于组织证据，但大部分是标准工具，不能仅靠换术语构成新颖性。

还未成立：画像代理误差足够小即可保证真实有限搜索Recall提高；GT10在全H/全base动作中最优；十目标优于任意目标数量；只靠增大网络或数据必能突破；当前七策略高预算oracle能代表全H高预算oracle。详细证明、条件、反例见theory.md。

相关前作直接约束论文定位：GATE已有学静态入口表示与小图；NGFix已有排名瓶颈/可达性；SIGIR 2024分区路由有不同的代理桥梁；EDBT 2026已有历史查询辅助入口。理论贡献应放在本问题特有的可验证桥梁和适用范围，不放在“用了GT/RL/双塔/查表”。完整逐项区别见文献核对。

7. 下一步建议

主线先转为完善GT10的机制与边界。 用现有强基线、完整公平曲线与受控反例组织论文；重点补H选择/画像/小图归因和新query来源稳健性，而不是继续证明已经知道的闭式均值最优。

入口算法仅保留一个可证伪的信息方向。 研究原路由已经产生的状态能否支持离线编译的入口选择，在线只查表/回退；若允许候选超出原top3，应明确这才可能接触本轮发现的多数遗漏机会。现有四动作表仍缺对齐信息/成本，新扩展更未完成新颖性和泛化证明，实施GO仍为0。先同监督固定/打乱/简单表控制，不能直接上新网络。

较大的收益需要单独讨论范围扩展。 若目标工作点的允许入口族确实无足够空间，再考虑query感知大图或自适应预算；与RoarGraph、NGFix、CDMG、Ada-ef对照，并明确改变了当前固定底图/固定L范围。当前数据还不足以宣布必须改图。

每条的具体机制、最小证伪、同监督控制、成本和停止边界已写在directions.md。本轮没有找出新的稳定胜者；找到的是可验证的原因分层，和不该再盲目投入的分支。

8. 本轮产物与证据边界

新增3个只读核算/核验脚本与绘图脚本、23点响应统计、4组全H机会分布、4组同批候选覆盖分解、完整E103门槛重算、理论/文献/方向文档及4幅三格式图。没有新ANN/NSG、GT、图、模型训练、性能计时或新鲜测试载荷。统计都是已曝光历史query上的描述性结果；没有事后改模型、追调参数或重开旧runner。

数值核验是同一会话的另一份实现，**不是独立人员/代理审稿**。代码和输入身份见主核算完成、机会分解、独立算术核验。旧源、图、标签、结果保留，根四文档仅同步本研究记录和下一边界；最终状态与封存见state.json。

改进方向：按证据排序，而不是按模型复杂度排序

当前没有获得稳定替换GT10的新方法。以下是研究方向及停止条件；未训练、未导出新策略、未读新鲜测试集，也未改变默认。特别是已停止的GT10画像调参、C8换点RL、WFree、多画像、E117树、E118/E119评分器、TargetKNN不能按新名字重开。

第一优先：把GT10本身做成可解释、可复现的强基线与理论结果

具体问题。 不再把“整个GT10系统胜NSG”当成“top10标签画像已被证明大幅胜GT1”。把H的选择、画像、路由图、入口数和主搜索内核分开。现有数据足以写出可信的阶段性结论；完整因果份额和跨来源稳健性仍未闭合。

可交付贡献。 一个无梯度、静态小索引的query分布压缩方法；一个明确区分代理质量、可达机会、可预测残差和完整成本的评价框架；一组可以推翻直觉的实证——更高覆盖/更准画像排名/更多入口都不保证更高实际Recall。这比宣称“新RL模型又提高0.1pp”更符合当前证据。

下一份严格设计应回答三件事。 QGT选出的H与同容量不使用GT的H相比是否仍有稳定优势；在相同H上GT1与GT10的差异能否在新查询来源重现；在固定评分及一致层级的控制下，画像诱导的小图节省的邻边扫描能否稳定转成完整时间。每个比较内部保持同一底图/内核/K/L，避免将不同图或实现收益混入画像贡献。

已有与缺失。 E107/108/115已提供强的同H和小图证据；E27/E106约束了“ESS就是原因”的说法。缺的是新来源下的完整因素核验与GT-inclusive离线成本账。这里不安排一套新的大网格，也不声称现在已经具备论文级新颖性。若GT10对GT1的增益仍不稳定，就把贡献定位在简单强系统与边界，而非强行证明“10”最优。

理论主线。 以theory.md的闭式最优性、方向误差与排名间隔、有限搜索响应、候选/信息/估计三项分解为骨架。真正值得新增的是能事先预测“代理改进是否会越过搜索响应边界”的可检验条件；只重证球面均值最优不足以形成新贡献。

第二优先：只保留“原路由状态能否免费提供不同的信息”这一信息假设

记录126提出了上层终点z到四动作表：原top3或其rank-single。它仍是`HOLD`，没有新增实施GO。本轮同批分解进一步说明，这四动作只覆盖全H oracle增益的21%–32%，所以不应继续把它当作大幅提升的主要承诺。

若继续入口方法研究，值得讨论的新机制是：用原路由已产生的离散状态，在离线阶段编译一个真实hub ID，允许落在当前top3之外，在线只查表或回退。 这是一个尚未成立的假设，不能立即宣布比旧方案更好。原图上层状态最多52，理想静态表可很小，但状态导出/分支/cache及不同入口的主搜索代价仍须计费。

它试图同时解决两个已测障碍：候选受限与全H在线评分太贵。与E117的差别在动作可超出原top3、信息是已有路由状态；与E118/E119的差别在查询端不做全H打分，而把选择离线编译。该状态是query与图的确定函数，所谓信息差别是廉价可用的结构摘要，非增加了超越完整query的信息。**这仍有GATE、算法选择和历史查询入口复用的前作，不能把组合本身当新颖性证明。**

先证伪信息，不先训复杂网络。 在角色冻结的历史开发query上，用真实路由状态与同预算真实动作标签对齐；比较默认、仅训练侧选出的全局固定动作、按z分组的简单均值表和保持组大小的打乱状态表。所有分组、动作提名及回退选择必须只用训练折；外折只报告，不能挑外折赢家。多K分别评价，不用K100变化替代K1。

这一步若只复用现有L128全H标签，最多证明L128局部信号，不能宣布R90改善；目标预算需另有对齐标签和完整计时。表只有52格意味着平均每格约79条query（4096/52，实际不均匀），但每格从约800个动作择优会产生明显选型偏差；不能因表小就认为统计可靠。不能通过增加格子、换节点/seed或更复杂分类器来回避第一轮失败。

明确停止预测。 若外折净成员增益不能超过强固定控制和打乱控制，或者只出现收益次数增加但损伤幅度更大，停止这个信息假设；若目标预算不保留收益，停止迁移；若完整成本吃掉节省，停止部署。数值门、数据角色与预算必须在任何后续实际试验前冻结，不能使用本报告的事后oracle定门后宣称预注册。

当前缺口。 没有现成对齐的z、目标工作预算全H响应与完整成本；本轮没有导出这些信息、拟合查表或启动试验。该方向是一个可反驳的研究提案，实施候选数仍为0。若这些缺口不能以合理成本补齐，应选择第一方向收口，而不是跳到MLP/双塔/RL。

第三优先：将“入口问题”与“底图/预算问题”分成两条研究线

本轮高预算七策略oracle较小，只能说明现有七种策略互补性不足，不能证明所有H或所有base入口都无效。全H标签目前仅L128；Web R90工作区间远高于此。因此，尚不能凭现有数字宣布“入口已经到天花板，必须改大图”。

若未来目标确实是较大的系统增益，可把“更适合query分布的底图”列为范围扩展方向，先核对RoarGraph、NGFix、CDMG与hubness研究。这里应研究同一查询分布下的可导航性、目标间连通和主搜索工作量，而非继续在固定H画像上扰动。也可以另立自适应预算方向，对照Ada-ef等已有方法；这会改变当前固定L约束，不能计作本轮入口改进。

范围扩展前的判别。 先分清目标工作点到底是“有可救回动作但识别不了”，还是“所允许入口族也没有足够空间”。前者优先处理信息/可索引性，后者才为改变图或预算提供直接动机。一次统一设计的诊断比在两条范围混杂的曲线上追小差值更有解释力。

目前不建议投入的方向

方向	不继续的具体理由
更深MLP、双塔、TabM或更多训练轮	E119强控制能拟合但未迁移；目前没有新信息/监督桥梁。更多参数不是待解决机制。
再调GT10温度、GT数量、收缩、画像模态数	已停止的固定H画像/图增强分支；“10未被证明最优”不是重新扫描参数的正面依据。
再做同C8组合RL/直接奖励	E32/E36已比较真实联合收益及同策略控制，开发/成本限制均存在；需实质不同的信息或动作机制。
只追更高画像top3精确率、目标覆盖率	E109及精确排序控制表明，代理最优不等于实际搜索效用最优。
只优化TargetKNN推理速度	当前召回曲线即便在条件零新增费思想实验中，同召回收益也有限；没有新可迁移信息依据，压缩旧模型不足以构成主线。
宣称更多数据一定解决	query数量确实有限，但E105已给出独立来源负结果；没有测过足够的学习曲线或统计条件。
根据平均度继续删小图边	省扫描不等于保持有效入口；E115混合候选已失败，路径/层级/评分存在交互。

我的排序是：**先完成GT10的机制与边界论证；入口算法只保留一个低成本信息假设；若追求更大收益，再将改图/改预算作为明确的新范围。** 这不是停止整个项目，而是停止用越来越复杂的学生模型反复逼近尚未证明可迁移的残差。

一手文献核对与研究空缺

检索日期：2026-09-22；服务于“GT10为什么强、还能在哪里改”的问题。以下区分读到的方法/定理正文与仅核对作者仓库的项目。论文报告的加速比不移植成本项目的 raw-IP、固定 NSG、CPU15 单线程设置；没有运行外部方法。

一手来源	本轮核对内容	对GT10的直接含义与不可直接移植处
GATE，KDD 2025	§4.1–4.3：base侧分层平衡聚类选真实hub，结构与查询监督的双塔，静态高层导航图	“离线学入口表示、在线小图路由”已有直接前作。GT10区别应落在QGT选点、监督压缩和实际成本证据；双塔这个名称不是创新。GATE以路径步数构造正例，其L2叙述不等于本项目raw-IP、三入口联合beam保证。
Adaptive Entry，2024	聚类入口、在线最近入口，B-MSNET与Theorem 4.4	更好的起点可以改善特定路径长度上界，但上界变小不证明实际路径、有限beam命中或总时间必然变好；图/Voronoi前提要单独核验。
Learning to Route for ANN Search，ICML 2019	论文摘要与方法定位：学习图上路由的表示	真实搜索反馈和学路由都非首次提出；该方法涉及遍历规则，与本项目只换初始入口的作用位置不同。
Learning to Route with a Ranking Objective，SIGIR 2024	分区路由、GT所属分区监督、内部精确检索与排序目标	分区包含GT后能精确取回，因而有较直接的质量桥梁。入口“靠近GT”后仍需走有限beam，GT10缺的正是这一桥梁，不能直接借其一致性结论。
LIRA，2025	查询感知分区概率、冗余分配与自适应探测	与GT目标分布压缩有关，但其分区搜索/合并和本项目多入口共享一个候选池不同；冗余覆盖优势不能推导本项目加入口必有益。
SOAR，NeurIPS 2023，2024 arXiv版	§3.1–3.3：量化残差、两次分配的误差相关性	“最近的第二个选择”可能与第一个同错，提供研究动作互补性的动机；这里的对象是IVF分配，不是共享beam入口。不能把去相关公式直接套成已验证改进。
RoarGraph，VLDB 2024	OOD查询与GT分散性、query–base二部图及投影构图	支持“query分布信息有价值”的动机；实际改的是大图连接。它不能解释为现有GT10画像已获得同类结构保证，也不是当前固定图任务中的合法入口替换。
NGFix，2025预印本	§5.2 EH、Corollary 1、§5.3/5.4与Theorem 5	路径上最大query排名的minimax量、排名诱导子图可达性是直接前作。访问保证依指定算法与L；全Recall定理限历史query且不剪边。不能称本项目E111证书首次提出这类概念，也不能把充分条件当必要条件。
Maximum Inner Product is Query-Scaled Nearest Neighbor，VLDB 2025	§3：正数缩放query的排序不变性、缩放后NNS等价，SSG复杂度前提	为raw-IP理论提供参考；其复杂度分析使用同分布高斯/特定图条件，不适用于未经证明的跨模态NSG。缩放query与单位化base是不同操作，后者通常改变raw-IP目标。
Ada-ef，SIGMOD 2026	§5.2/5.3及§7.5：分数到ef的离线表，在线获取距离信息	小表和统计模型已有前作，表查找便宜不意味着获取特征免费。它逐query改变ef，当前固定L范围内不能据此宣称入口改进；两跳信息开销在论文消融中也有明确取舍。
Adaptive Query-Aware Hybrid Search，EDBT 2026	§2.3、§3.1、Algorithm 1：历史查询BST、估计recall、取历史结果作入口	“查询记忆+便宜组织结构+入口复用”亦有直接先例。它针对属性过滤与高阶遍历，并更新recall模型，不等价于固定NSG的纯入口策略；不能把查表方案直接包装成新的通用范式。
Clustering on the Unit Hypersphere，JMLR 2005	球面聚类和vMF框架	归一化加权均值是成熟统计结构。GT10的闭式最优性不需要vMF假设；若进一步声称Bayes最优分类，则要新增并验证分布、浓度及先验条件。
ALORS，Artificial Intelligence 2017	出版社摘要：算法响应矩阵的潜在表示与新实例选择	“服务能力/响应嵌入+query映射”属于已有算法选择框架。E119没有证明整个框架不可能，但新提案必须说明可迁移信息与这个前作的实质区别。

一手来源	本轮核对内容	对GT10的直接含义与不可直接移植处
Hubness分析，SIGMOD 2026作者仓库	仅作者README：高入度hub、anti-hub、长尾与剪枝干预；ACM全文本轮403	作为结构研究的排重线索，不能声称已读完其理论。本项目“入口hub”只是候选点名称，并不证明它是统计hubness的高入度节点；目前没有此因果归因。
CDMG，SIGMOD 2026作者仓库	作者README和作者主页核对；ACM全文本轮403	跨分布单调图已经有直接研究，若扩展到大图必须比较。仅凭仓库摘要不引用其具体定理或把作者加速比当本项目可达到的收益。

成本敏感决策的前作边界

项目今天的记录126已经逐项核对FrugalML、RouteLLM、多专家延迟决策、Selecting Computations、SATzilla与算法组合。本轮继承其“信息获取费、选择遗憾、完整wall必须一起核算”的问题分解，不将其重述为新的ANN算法，也不把LLM/API的成本尺度迁移到微秒级入口选择。

目前真正未闭合的问题

1. **归因缺口。** 现有系统收益里，QGT选择真实H、画像评分、画像诱导的小图状态分别贡献多少？E107/108/115已排除一些简单解释，但没有跨新查询来源和大图的完整因子分解。单位hub控制仍继承GT选出来的H。
2. **桥接缺口。** 代理排序的误差何时会改变真实入口响应，何时仅改变路径/工作量，何时完全不变？已有有限beam/局部最优理论只覆盖部分机制；NGFix式充分条件不是现成充分解释。
3. **可支付信息缺口。** 已有全H oracle很大，能被低成本、查询外信息识别的那部分未知。平均MSE、oracle和拟合内收益都不能填上这个缺口。
4. **跨预算缺口。** 候选排序依赖K与L；E120已测得预算迁移损失，目标预算kNN又未胜简单控制。不能继续假设“学好L128就自动提升R90工作点”。

这些是研究问题，不是新颖性已成立的结论。当前最可信的论文组织方向是“强简单入口基线及其适用边界 + 可审计的效用分解”；算法贡献需要额外的正面结果。没有根据给出会议等级保证。

检索边界

查询覆盖入口选择、学习路由、OOD图、搜索难度、hubness、分区路由、统计画像与低成本决策。上表每项只记录实际查看的层次；没有把搜索命中数量当系统综述的完整性证明。外部PDF访问失败不影响本项目原始数据的核算，也不以二手AI摘要替代缺失定理。