# GT10理论与性能改进研究

2026-09-22晚间研究。原17:00交付已独立封存；用户随后授权实际改进并延长至22:00，只有理论和经核验的完整性能同时提高才提前结束。21点后用户进一步要求复测E125并调整旧门一票否决；冻结模型的Web新查询单点测试已于21:21前完成核验。随后完成研究策略、理论和交付审查。

## 当前判断

**GT10仍是默认，没有出现经过完整Recall–QPS验证的新替代方法。理论解释已经更具体：它把GT引导的真实入口、稳定的查询方向画像和便宜的小图路由结合起来；后继模型虽然能学到关联，却常常没有学到值得付在线费用的入口决策。**

当前WebVid使用GT10-soft-t1，Yandex使用GT10-hard；生产主搜索保持E99。E103仍是最近完整五数据集重测，E118仍是最近宽预算候选前沿。最新轻量三点比较是E125：标签费用明显降低，原Web非劣区间门未过。用户随后授权冻结模型新源复测，Web K1/L1000少命中6/4096（−0.146484pp）、完整QPS−0.104439%；现在保留为低成本候选，未证明无损，也不替换默认。旧门不再一票否决探索资格。

“几十次没有超过”不能解释成GT10全局最优，也不能都归为实验错误、模型不够强或数据量不够。多条分支已通过原生返回、GT语义、角色隔离和独立数值实现检查；部分候选存在局部召回正值，却支付了更大的查询时间或没有迁移到新来源。

## 1. 已经确立的性能与边界

下表取E103中各方法达到90%门槛的最快已测配置；方法实际Recall和L未必完全相同，不是同Recall插值显著性结论。

| 数据 / 指标 | GT10 Recall | GT10 QPS | 原NSG QPS | QPS差 |
|---|---|---|---|---|
| WebVid / R1 | 90.7500% | 520.79 | 416.68 | +24.99% |
| WebVid / R100 | 90.6868% | 340.46 | 337.80 | +0.79% |
| Yandex / R1 | 91.0500% | 2406.16 | 2194.80 | +9.63% |
| Yandex / R100 | 90.9805% | 1241.64 | 1160.90 | +6.96% |
| Deep / R1、R100 | 94.13%、92.6021% | 8804.34、3503.61 | 7497.14、3298.49 | +17.44%、+6.22% |
| SIFT / R1、R100 | 95.91%、94.0603% | 7661.98、3015.93 | 7227.79、2922.68 | +6.01%、+3.19% |
| GIST / R1、R100 | 92.20%、91.67% | 1229.41、550.73 | 1220.23、550.43 | +0.75%、+0.05% |

后三集是已测soft配置，不是在今晚重新选择默认。GT10在Web/Y更有研究价值，在GIST并无普遍的大幅领先。公共搜索优化的收益也不能全部记给入口方法。完整曲线、三次计时范围与配置见E103原报告，门槛复算见17:00报告数据。

E118 GraphCost在20个匹配点逐query命中与默认相同，但全部QPS更低。E120后续补齐的三点三重复则在12匹配点召回均值全部增加，完整QPS下降约18%–54%。二者说明：“没有稳定替代”既包含没有质量增量，也包含增量抵不过费用。E105又表明旧开发上的画像改进没有通过新来源复验，不能用反复曝光数据上的正点宣布替代。

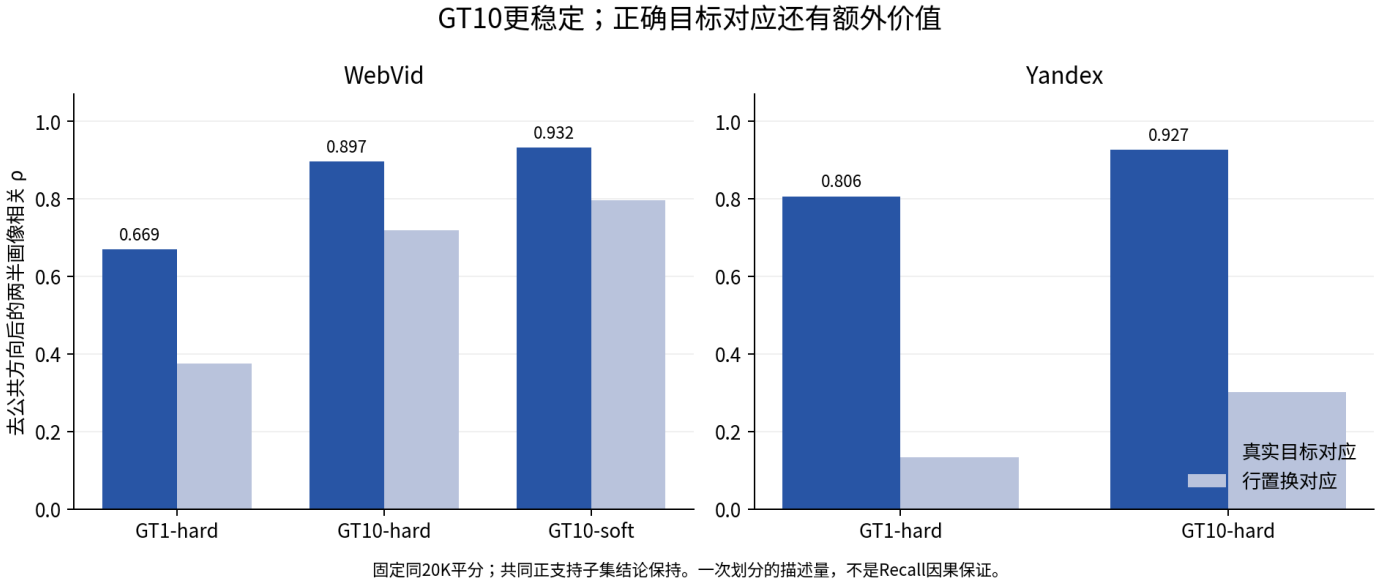
## 2. GT10好在哪里：从合理故事到可核查证据

第一，真实入口H不是随意抽样，而是QGT监督选出的候选。原单位hub单入口已经获得相对固定NSG的大部分收益，因此整体优势不能全算作“用了十个目标”。

第二，画像使用query方向累加，解决的是query与base分布不同的问题。公式p_h=unit(u_h+Σ_i a_ih x_i)对固定加权亲和目标有闭式最优解。它用20K query把监督压缩到815/821个方向，推理继续使用原小图。GT10并不是对稀疏有限搜索残差做800多个独立复杂回归。

第三，本轮实际归一化画像的稳定性证据成立，而不只停留在ESS或未归一化统计矩。

| 数据 | 方法 | 固定两半画像夹角中位 | 去公共方向后的ρ | 打乱对应后的ρ |
|---|---|---|---|---|
| Web | GT1-hard | 24.51° | 0.6693 | 0.3756 |
| Web | GT10-hard | 12.13° | 0.8966 | 0.7188 |
| Web | GT10-soft-t1 | 8.54° | 0.9325 | 0.7963 |
| Yandex | GT1-hard | 27.23° | 0.8061 | 0.1333 |
| Yandex | GT10-hard | 16.49° | 0.9268 | 0.3005 |




固定相同20K随机平分，限制GT1两半都有正支持的hub仍保持结果；真实对应的跨半亲和在十个方向上都超过保持质量结构的置换，也超过全局query均值。但置换GT10本身也更稳定，因此一般平滑与正确语义对应都有作用，不能把稳定性全部归于GT语义。十个目标相关，样本单位仍为query，不是独立样本数乘十。

第四，画像还改变小图可检索性。已有E115的证据是扫描邻边减少，不能声称走过的节点或路径都更少。亲和、路由误差、有限主搜索、最终wall之间仍有不同桥接条件。

因此，当前可支持的解释是**稳定且有语义对应的静态压缩，加上适合现有系统的低成本推理**。尚不能支持“GT10对真实Recall理论最优”“10是最优数量”“soft一定更强”或“稳定性解释全部收益”。详细理论及画像控制与核验保留条件与反例。

## 3. 今晚实际检验了什么

所有候选只用原底图、原主搜索和已曝光训练来源；四折外折属于开发控制，不冒充新盲测。下表u为ΔRecall−0.1×旧graph-only相对时间，等K平均。它没有包含新评分、路由全部在线费用，不是QPS。

| 阶段 / 唯一主候选 | 新假设 | Web ΔR1 / ΔR100 pp | Y ΔR1 / ΔR100 pp | Web / Y u×100 | 结论 |
|---|---|---|---|---|---|
| E121 StateCost | 原路由上层状态可支撑全H动作表 | −1.0742 / −0.3154 | −0.3418 / −0.2839 | −1.1668 / −1.1385 | 停止本版 |
| E122 FunctionSmooth | 相近真实入口响应可共享统计 | −0.1709 / −0.1182 | −0.2197 / +0.0139 | −0.5326 / −0.9519 | 停止本版 |
| E123 TargetService | 目标区域到实际成员服务有迁移结构 | +5.3955 / +0.1709 | +2.5635 / +0.7129 | +2.9808 / +1.6965 | 仅特权信息门通过 |
| E124 SemanticService19k | 将目标语义预测与服务表静态编译 | +0.0732 / −0.0073 | 0 / −0.0334 | −0.0762 / −0.4888 | 停止本版 |

E121确实胜打乱状态，但不胜默认；51/52种状态面临约800动作，表项跨折不稳定。E122先证实入口响应的局部性，正确几何正则减轻独立回归的损失，却未胜同谱打乱关系，也未超过默认。相关结构存在，不等于当前估计器能用好它。

E123最有价值的正结果是：真实GT目标区域经过实际搜索服务表后，可以产生超过默认的策略。它不需要假设“目标属于这个区域就一定有用”，而用训练响应建立区域—入口关系。不过真实GT在线不可得，获取费用也未包含，故它不是性能新方法。

E124把上述服务关系与query语义预测合并为静态仿射评分。它比直接回归实际效用好，但主效用仍未过正门，亦未胜打乱服务控制。用更多历史语义query后，区域预测MSE和准确率改善，决策没有同步改善；固定α下有效正则强度也改变，不能据此单独归因为样本数。

原协议、全部控制、独立核验与成本分别见E121、E122、E123、E124。没有把失败版本换参数或换名字继续训练。

## 4. 为什么预测更准仍未赢：本轮最关键的理论修正

常见设想是“既然真实GT区域有帮助，就先把GT区域预测准，再接一个服务表”。问题在于服务表本身不一定是query条件下的真实动作价值。

令g=AS为真实GT区域构成的服务代理，ĝ=ÂS为预测服务代理，u为实际效用，r=u−g。特权策略a_g和学生a_hat之间有逐query精确分解：

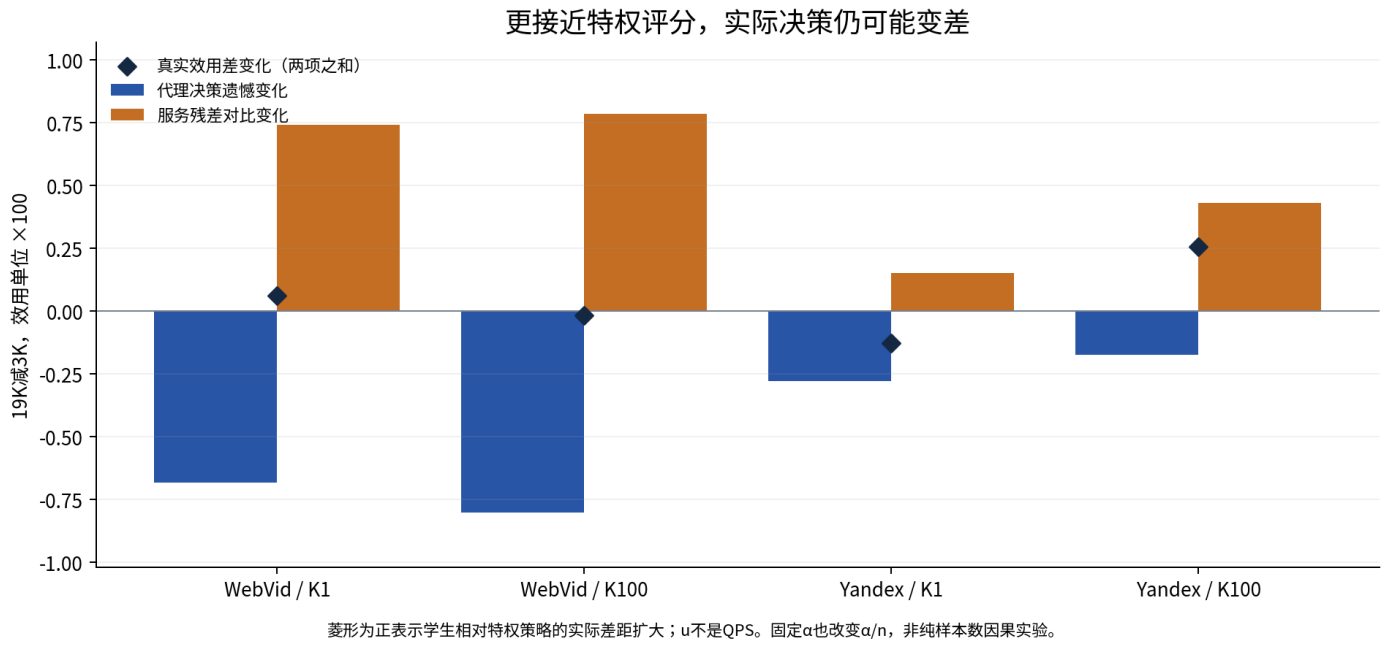
`u(a_g)−u(a_hat) = g(a_g)−g(a_hat) + r(a_g)−r(a_hat)。`

学生更像教师会减小第一项，却可能增大第二项。本轮19K对3K四格的语义MSE、服务MSE和代理决策损失全部改善，真实效用仍两格升、两格降；这些差异已逐query恢复。**一个好用的特权策略，只证明这条策略有效，不证明它的全部评分都适合让便宜学生逼近。**

区域条件平均E[D|G]再按query目标区域平均，一般不等于E[D|q]。区域内query、目标rank和有限搜索状态的差异可能被抹掉；条件期望不能任意交换。负语义分量不是该失败的必要条件，已有合法概率反例。换softmax、决策损失或更大模型都不能自动消除服务代理偏差。

另一个限制来自排序：在E122主模型上，即使免费准确决定是否采用当前最高分入口，也只能取得全H召回余量的约13%–23%；当前遗憾的76%–86%来自排序。不能把失败简化为“只差一个回退阈值”。这些比例只属于被诊断的当前模型。

这使理论比“监督噪声大所以深模型失败”更具体：应分别核验代理偏差、便宜表示可预测性、动作排序、近似路由和完整成本，而不是继续优化同一个可能失配的代理。见精确分解与反例、数值核验、排序/回退分解。

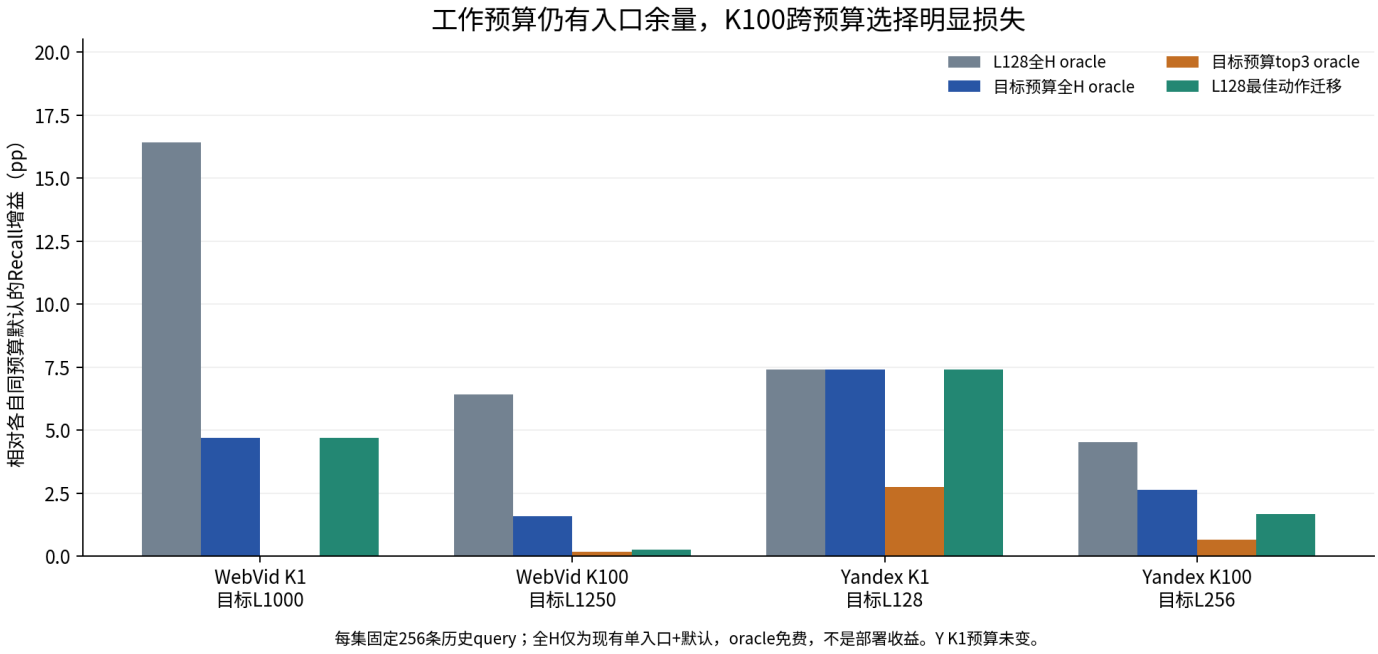



## 5. 实际工作预算下的全H余量

固定256-query全H诊断与独立审计已完成。Web K1/L1000、K100/L1250及Y K1/L128、K100/L256的默认Recall都超过91%，全H-single+默认事后增益仍分别为4.6875、1.5859、7.4219、2.6406pp。原top3-single+默认仅覆盖0%、10.34%、36.84%、24.85%的机会。

相同样本L128最佳入口迁到目标预算，K100只保留目标oracle的Web15.76%/Y63.31%；Web K1却保留100%，不能把预算迁移统一说成失败。高预算余量减少但未消失，候选之外仍有机会；低预算反馈和廉价线上决策之间仍缺可靠桥梁。

这补齐了“此前七策略趋同是否代表全入口无空间”的证据缺口，但没有新方法GO。样本为256条历史fit、K1单query步长0.390625pp，oracle免费用真实标签且仅含现有H单入口。628404次新NSG、777.022秒CPU15单线程作业，全部返回和统计独立核验通过；没有QPS测量。完整表、区间与冻结策略迁移。



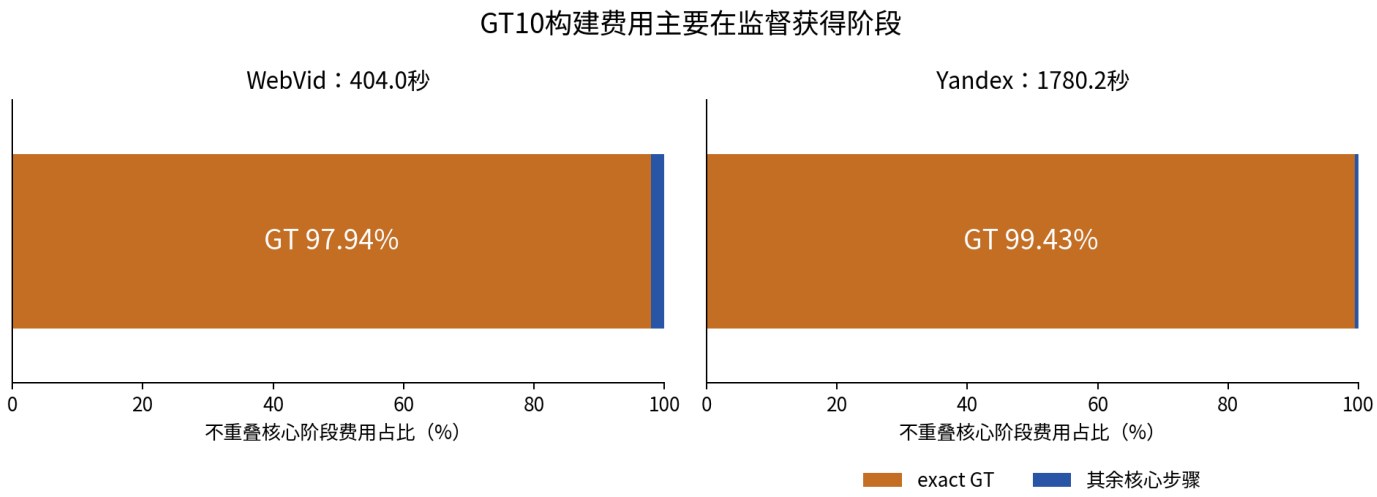

## 6. GT10完整入口构建成本

当前默认从训练GT起算的重建已通过：两集各QGT5K+画像20K，合计5万条exact top100全部恢复旧GT；H、画像逐位相同，两张Micro-HNSW结构及5万对旧/新路由一致。

| 不重叠阶段（秒） | Web | Yandex |
|---|---|---|
| exact GT搜索 | 395.684 | 1770.125 |
| base加载/Flat建立 | 6.054 | 9.379 |
| QGT选H | 0.365 | 0.177 |
| GT10归属与画像 | 1.839 | 0.506 |
| 小图构建 | 0.055 | 0.045 |
| 核心阶段合计 | **403.997** | **1780.232** |

GT占核心阶段97.94%/99.43%。这是未清缓存、CPU0–7、各库池上限8的单次离线测量；15个驻留线程限制在8个CPU上，不能称实际只有8线程。合计不含阶段外校验/I/O、下载、嵌入、公共底图及历史选型；为恢复旧账本生成top100，画像实际只用top10。完整过程与各阶段不能重复求和。

因此GT10的优势应写成“把较昂贵的一次性监督压缩成便宜在线路由”，而不只是“画像几秒”。独立完整GT比较、图格式解码及旧文件身份检查通过。完整费用与核验。

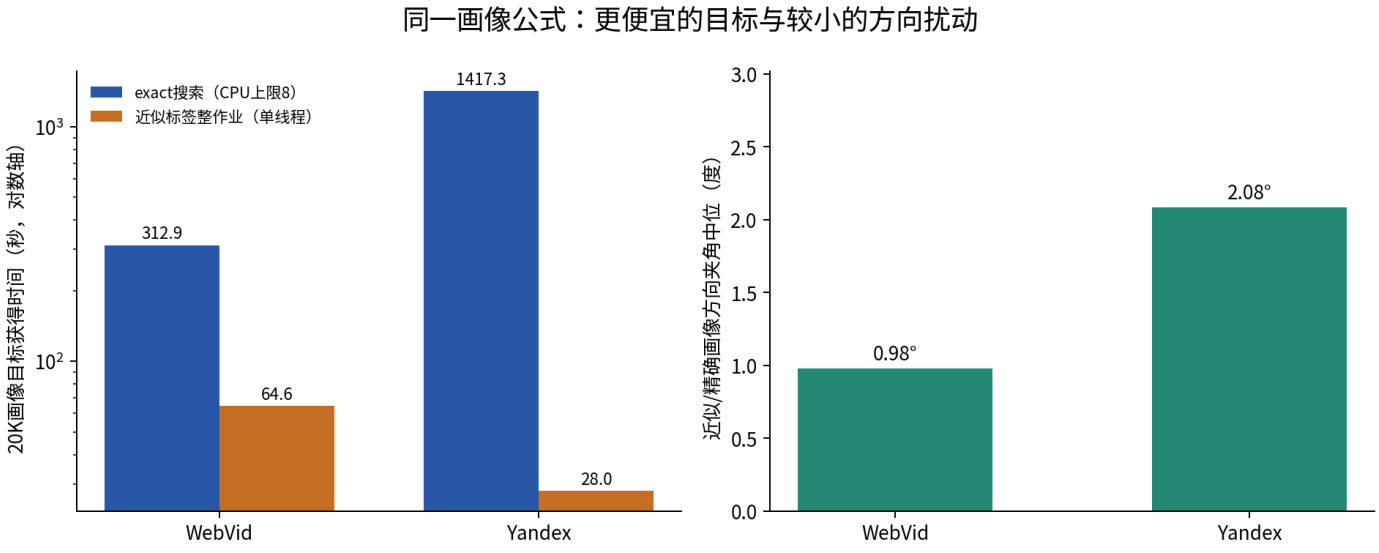



单次、未清缓存，CPU0–7；合计不含阶段外I/O和审计、下载/嵌入/公共NSG/历史选型。不是查询QPS。

## E125：稳定画像能否使用更便宜的目标

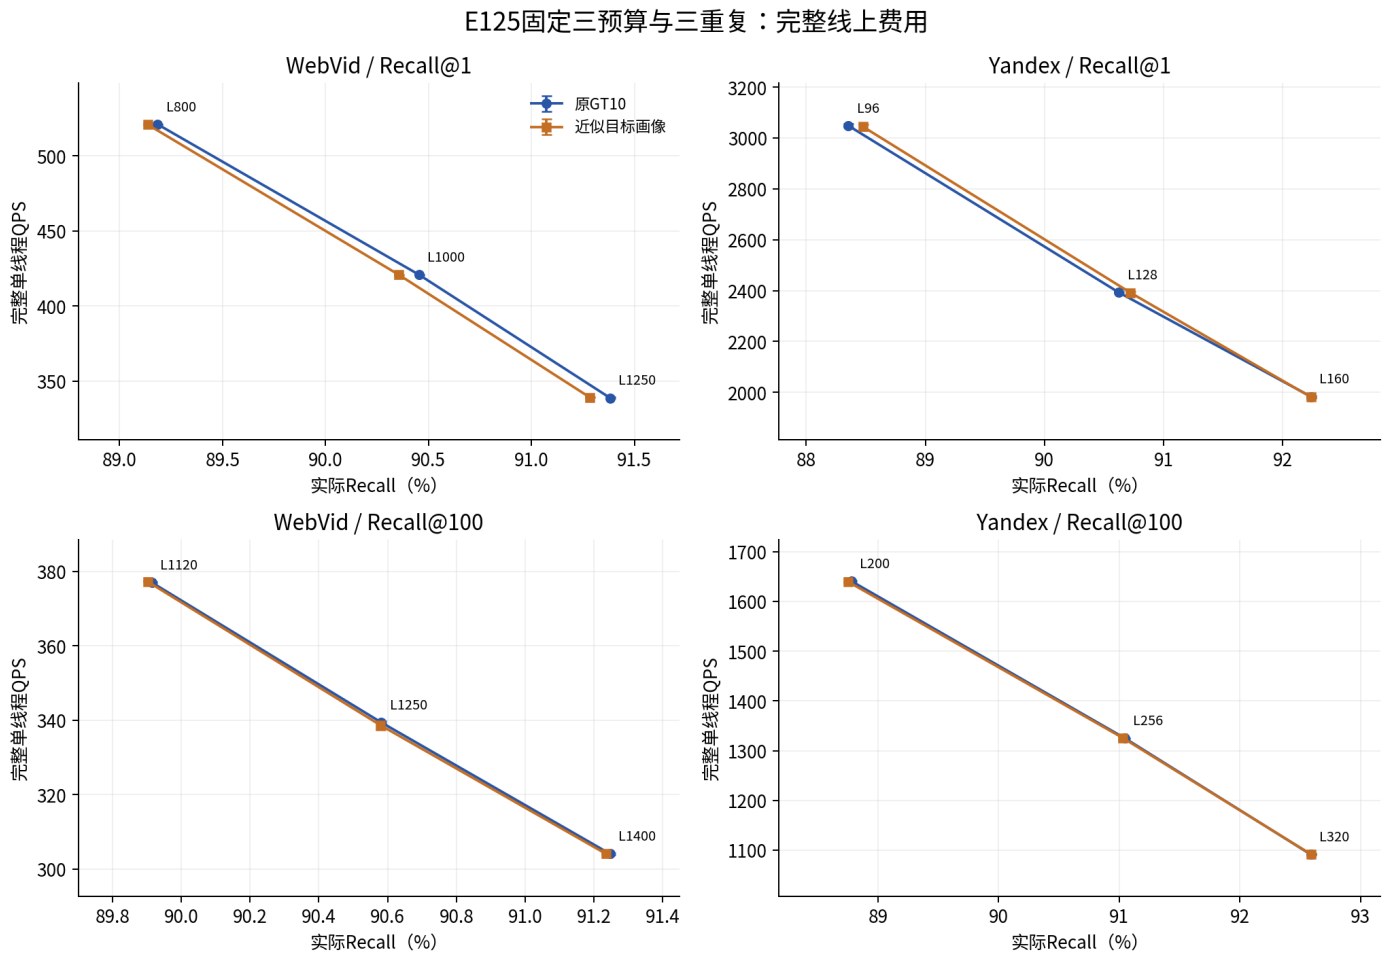
依据上述新成本证据，另冻结一次近似目标试验：原H、20K、十目标公式及小图不变，用固定NSG medoid产生近似训练目标。QGT5K exact监督仍保留。候选标签作业单线程64.591/28.040秒，对应原八CPU exact20K搜索312.862/1417.293秒；资源条件不同，不宣称同线程加速比。新画像相对原件夹角中位0.980°/2.082°，两个exact控制逐位恢复。

追加源码追踪确认：Web温度0.016201138496398926由原20K精确GT1的hub分数间隔标定，E125直接继承；Y-hard没有温度依赖。因此费用改进限定在**既有H和参数固定时的近似标签获取**，尚未完成新数据集从零构建的低费用验证。原脚本还读取exact GT做控制/诊断，不能将研究作业宣称为完全不需旧GT的部署流程。这个范围不改变新查询Recall/QPS，但冷启动需要单独解决温度来源。 费用依赖审查。




QGT5K仍用原exact监督；资源条件不同，非同线程加速比。少量入口偏移更大，中位数不保证最终Recall。

在E105已曝光、训练query字节互斥的4096query/集上，12匹配点、三次完整单线程wall全部执行。QPS变化−0.2161%至+0.0893%，各点召回均值损失不超过0.10pp。可是Web K1/L1000为−0.097656pp，98.75%区间[−0.292969,+0.073242]，未达到预锁下界≥−0.25pp；因此旧协议记录为**STOP_APPROX_TARGET_PROFILE_PILOT**。这个历史门未过不等于已经证明质量退化，也不等于后续没有验证价值。用户已明确调整策略；原门和原结果不改，当前候选资格由下述新证据与实际成本取舍重新判断。




E105已曝光但训练字节互斥的4096 query/集；误差线为三次QPS范围，非置信区间。此图不构成默认替换。

两候选画像、全部98304返回、12默认点的60数组及四区间独立核验通过。初版复用工具加载了未调用的GT10 router，另完成不读取画像/图的生成器及64条完整标签/E99核验；原4万标签和计时保留，不扣除多余加载成本。合计532096新NSG、2候选画像/图，0新exact GT或新来源。全量方法点、费用及修正见E125报告。

## 用户要求的单组新查询复测与策略修订

模型、训练目标、预算和图不改，只从另一源窗口取4096条与登记split、E105整个20K窗口及原拟合输入无字节重复的query，再生成精确GT。固定Web K1/L1000、三次完整单线程wall，结果如下。

| 方法 | Recall@1 | 命中 / 4096 | 完整QPS |
|---|---|---|---|
| 原GT10-soft-t1 | 90.795898% | 3719 | 419.559 |
| 原ApproxTarget10 | 90.649414% | 3713 | 419.121 |

救回6、损伤12，差−0.146484pp，单点配对bootstrap95%描述区间[−0.341797,+0.048828]；QPS−0.104439%，两方法三次范围重叠。旧批次同点净损4条、新批净损6条，支持小质量代价的判断，不能只称随机误差或无损。与此同时，构建标签费用优势具体存在，当前证据也不足以据单点区间否定整条近似监督路线。

**当前判定为保留低成本候选，默认保持。** “能否继续探索”与“能否替换默认”分开：效应量、成本收益和复测一致性决定探索价值；默认替换仍要与应用可接受的质量取舍匹配。未证明非劣记为证据不足，不直接记为方法失败。旧98.75%门不回写为通过；这次95%只属于预先冻结的单点描述。

新4096 GT、40992 NSG、40960 ANN，0新训练/图；实际1线程、warm/plain/count和32次E99检查通过。8192返回独立重评分，另用精确卷积复核bootstrap端点；源和模型身份保持。源顺序窗口不是全源随机或语义独立证明。首次启动监控在taskset绑定前误触发、0搜索，修正监控时序后一次完整运行；全部原件保留。复测报告 · 新策略。

补充对齐全部入口与返回：新Web有1150/4096条查询更换三入口集合，但仅21条改变最终K1返回ID；旧Web/Y对应1111/875条换集合、13/27条改返回。小画像扰动并未保证入口不变，却在当前预算下大多保持最终返回；这支持区分路由变化与实际搜索增量，不能解释为轨迹相同或全H无余量。只读逐行核验。

## 7. 实验错误、费用与证据身份

本轮保留了所有发现的错误和失败前件。E123首次拟合前发现同分重复向量使“GT1在K100池中”等价“实际K1命中”的前件不成立：原ID、query和收益评分保留，只把服务标签语义修正为池成员包含，随后在v2首次拟合。E124独立正规方程、全动作及query字节隔离通过。机制分析和准备脚本的编译/索引引用错误均在产生相应有效结果前停止，原文件和修正版分开保留。

独立核验指同一agent另写计算实现，不是独立人员盲审。已有缓存时间不包含新预测费用；GT、画像和路由重建属于离线费用；全H搜索作业时间属于标签生成费用。所有完整查询性能仍沿用CPU15实际单线程、方法串行的规则。没有把标签作业或NDC换算成新QPS。

今晚候选离线拟合本身很便宜：E121约6.16秒，E122约10.39秒，E123有效拟合约10.71秒，E124约13.62秒；这些数字排除继承响应标签获取费用及独立审计。后继模型原有全H标签成本达数小时，不能假装本轮重用标签就不曾有成本。画像稳定性新增25次闭式聚合；不会写成“零拟合”。

## 8. 最后的改进方向

第一，保留ApproxTarget10为明确降低监督获得费用的工程候选，按实际应用权衡小幅召回差，优先补真正影响取舍的证据；不要求所有探索点先同时显著。Web两批均小幅为负需要如实保留，不马上重训或在这批新测试上调整教师。

第二，完善GT10的条件理论：加权query方向是估计对象，十目标降低波动与正确目标对应各有作用；近似标签误差应看对画像方向的扰动，再连接到排名margin、实际路由和有限搜索。第三，若目标仍是显著线上提速，应寻找工作预算上便宜且可迁移的动作信息；E123特权收益不自动变成学生收益，全H仍有空间但当前模型无法稳定兑现。

只读训练缓存已补核算：随机残差校正要在合力归一化的向量总和MSE上优于直接近似，Web/Y解析临界m约3269/8517，占20K的16.34%/42.58%。残差方差虽小，直接近似偏差也已部分抵消，少量补标不必更好。没有据此训练模型或选择m；这不是Recall门或否定混合监督，只用于评估投入。 只读核算。

E121/E122/E124的已测负结果保留，后继按实质新证据和预期价值决定投入；历史STOP不作为对有理由的冻结复测的永久禁令。今晚这一组已完成，没有追加到通过的队列。详细操作与论文边界见改进方向。

前作与方向条件见理论、特权学习与预测后优化原文范围及17:00完整调研。

# 改进方向与下一步

2026-09-22按最新用户意见调整。当前默认为Web GT10-soft-t1 / Yandex GT10-hard、生产E99。今晚没有新的线上Recall–QPS稳定替代，但近似目标已经形成有价值的构建费用候选。新源单组复测完成，后续不受旧单点门的永久禁止，也不启动未经设计的参数扫描。

## 1. 先保留最具体的改进：低成本GT10

E125将20K画像目标获得时间从原exact搜索312.9/1417.3秒，变为近似完整作业64.6/28.0秒；前者CPU0–7、后者单线程，不能宣称同资源加速比。QGT5K精确监督仍存在。原12点完整QPS几乎不变，画像中位偏移约1°/2°，这已经是一个值得保留的工程结果。

追加源码追踪确认：Web温度0.016201138496398926由原20K精确GT1的hub分数间隔标定，E125直接继承；Y-hard没有温度依赖。因此费用改进限定在**既有H和参数固定时的近似标签获取**，尚未完成新数据集从零构建的低费用验证。原脚本还读取exact GT做控制/诊断，不能将研究作业宣称为完全不需旧GT的部署流程。这个范围不改变新查询Recall/QPS，但冷启动需要单独解决温度来源。 详见源码与条件。

Web K1/L1000旧批−0.0977pp，新批−0.1465pp；新批救回6、损伤12，95%描述区间[−0.3418,+0.0488]pp，QPS−0.1044%。这表示目前更适合定位为降低构建费用的质量取舍，不是完全无损或线上加速。若构建频繁或标签成本重要，价值较高；若GT可以长期复用且必须接近无损，原GT10更合适。不要重复计费可复用GT来夸大节省。

下一项值得做的是**固定现有模型的成本—质量确认**：先按真实用途选最关键的K/L与来源，给出可接受的实际损失和测试预算，再补一组能影响选择的证据。已有两批Web K1、原双集K100等结果必须同时呈现。不是要求每点显著，亦不是增加样本直到通过。本次新批已曝光，不得拿来选择教师后再充当确认集。

若要进一步减少观察到的质量损失，先利用原训练侧精确/近似目标统计区分：漏掉目标是否改变目标所属hub，还是仅目标ID改变；加权扰动是沿原画像方向还是使其转向；大偏移是否集中于少量弱支持画像。该诊断可以指导一个有限的训练侧纠偏假设，例如只对预先识别的不稳定训练子集做精确监督，并明确计入筛选和追加标签费用。**这些诊断和混合监督尚未实现**，不得依据新测试失败query选择补标，也不声称它必然有效。

一种值得比较的最简单纠偏，是在预先随机抽取的m条训练样本上补精确GT，用“全量近似贡献 + N/m倍抽样精确减近似残差”恢复原画像向量总和。固定教师/H/参数时该向量估计设计无偏，方差取决于残差；归一化方向和Recall仍无无偏保证，少量稀疏残差可能反而加大误差。这是经典差值估计，不是新颖性声明，也尚未执行。应和相同m精确样本单独构建对照，不能先挑新测试损伤query。 推导与前作。

只读训练缓存已补核算：随机残差校正要在合力归一化的向量总和MSE上优于直接近似，Web/Y解析临界m约3269/8517，占20K的16.34%/42.58%。残差方差虽小，直接近似偏差也已部分抵消，少量补标不必更好。没有据此训练模型或选择m；这不是Recall门或否定混合监督，只用于评估投入。 残差诊断。

## 2. 把GT10为何有效写成有条件、可验证的理论

最稳固的解释链是：GT监督选真实入口；十目标归属形成稳定的加权query方向；归一化均值在固定亲和代理上有闭式解；静态画像与小图把监督压缩为便宜在线选择。两半画像稳定性和正确语义对应的额外亲和支持这条链，但不能保证有限搜索Recall。

论文应分别陈述估计对象、偏差与方差、方向扰动、排名margin、小图近似误差和有限搜索效用。十个目标相关，不能宣称十倍独立样本；unit均值不是一般的目标后验分类器。近似目标ID准确率也不直接决定画像方向误差，小方向差更不保证召回无损。可证明的条件命题与未满足的前件并列写明。

比较必须分清：整个GT10相对固定NSG；同QGT候选下GT10相对GT1/单位hub；新方法相对当前默认。单位hub也继承GT选H，不能叫完全无监督基线。小图扫描邻边少，不必等于路径或访问节点更少。

后续先整理已有H/画像评分/小图/联合初始化的消融覆盖矩阵，只补真正缺项。GATE静态路由、方向聚类、学习导航等前作不应重新命名为创新；研究价值应来自确切机制、可迁移证据和适用边界。

## 3. 线上大幅提升仍需找到便宜的决策信息

目标预算全H诊断说明还有空间：固定256条上Web/Y K100的single+默认oracle增益为1.586/2.641pp，当前top3覆盖10.34%/24.85%。但Web L128最佳入口迁到目标预算只取到该oracle的15.76%，低预算标签不能直接代表工作预算。oracle免费、样本历史曝光，不能视为可实现收益。

E123证明真实GT区域经过服务表有价值；E124表明预测区域更准不必提高决策，因为服务代理不一定等于查询条件下真实效用。当前优先问题是：什么廉价表示能在工作预算上保持入口动作价值关系，并且节省的主搜索时间足以支付它?

后继可以从已有响应检查遗漏的信息与预算关系，提出一个简单对照能区分的具体假设。先用便宜、固定范围的实验判断是否有信号；不要求探索阶段先获得全部显著性，也不因模型名更先进就扩大训练。RL/MLP/双塔不是被证明不可行，但模型复杂度本身不填补信息、代理偏差与在线费用缺口。

## 4. 今后怎么判断“继续”或“停止”

遵循研究判定策略：探索与默认替换分开；单点区间未过不一票否决；非劣证据不足不等于有害；成本收益可以成为独立目标。对接近边界且有实际价值的旧候选，允许先冻结范围再复测，不必改名或先发明新机制。

同时保留数据角色、计时口径和全部结果。明显且可复现的质量损伤、不可支付的在线成本，仍是停止具体实现的有效理由。复测固定样本和结束边界，不连续加批直到过线，不在确认数据上调参。旧E125的STOP保留历史身份，当前定位为RETAIN_LOW_COST_CANDIDATE，原默认与全部历史资产保持。

今晚没有额外实验队列。最具体的近期方向是把低成本候选的取舍讲清楚，并用训练侧误差结构指导有限纠偏；理论方向则完善稳定性到实际搜索的条件连接。

# GT10的强项与改进条件：本轮理论收束

2026-09-22。本文把已有条件命题、本轮机制证据和仍待证明的连接分开。闭式最优、方差恒等式和最大化遗憾界属于标准工具；研究贡献不能仅声称提出这些公式。新证据在画像方向复现、特权服务与学生决策的精确分解，以及实际工作预算的完整现有单入口响应。

## 1. 一个目标简单、估计稳定、推理便宜的组合

固定原真实入口集合H，令x为单位query，u_h为单位真实hub；a_h(x)是该query前十GT目标对hub的平均hard或soft归属，每query对全H总质量为1。实际画像为

$v_h = u_h + \Sigma_i a_h(x_i)x_i$，$p_h = v_h / ||v_h||$。

当v_h非零，p_h精确最大化单位方向约束下的加权亲和 $p \cdot u_h+\Sigma_i a_ih\ p \cdot x_i$。相同权重和目标上没有等待梯度优化器发现的更优解。画像把原20K query的监督压缩成H个静态方向，在线沿用小HNSW和真实入口；不存在在线再算GT的费用。

这不意味着无成本：入口集合本身也由QGT监督选择，画像需要训练GT，路由也占用时间。把raw-unit-hub称为“完全无监督”或把画像几秒当全部构建费用，都会误述优势来源。

## 2. 十目标的正确方差解释

条件于固定H，定义第t个目标对hub的向量贡献Z_t=b_th(X)X，a_h X=(1/k)Σ_t Z_t。只要二阶矩存在，就有精确恒等式

$\mathrm{tr\ Cov}[(1/k)\Sigma_t Z_t] = (1/k^2)\Sigma_t\Sigma_s \mathrm{tr\ Cov}(Z_t,Z_s)$。

在各rank边际协方差迹都等于$\sigma^2$、不同rank交叉协方差迹都等于c这一额外条件下，它成为 $\sigma^2/k+(k-1)c/k$。若$c=\rho\sigma^2$，则形式上的有效rank数为$k/[1+(k-1)\rho]$。ρ=1时无十倍方差收益，ρ=0时才有该理想比例；实际rank并未满足这些等分布或等相关前件，不能用该特例宣称GT10有十倍独立样本。soft与hard也改变目标均值，不能只比较方差而忽略偏差。

若query独立同分布，μ_h=E[a_h X]，m_h=μ_h+u_h/n，则样本平均误差均方为tr Cov(a_hX)/n。由非零向量归一化不等式得到

$E\ ||p_hat-unit(m_h)||^2 \le 4\ \mathrm{tr\ Cov}(a_hX) / (n\ ||m_h||^2)$，

其中要求归一化向量非零；零向量采用实现回退时要另外处理。这个界控制的是含有限prior的总体方向m_h，不自动控制无prior方向unit(μ_h)，也不假装实际query已经满足IID。分子是向量协方差，分母是合力强度；单独的标签质量或ESS不是充分解释。

本轮直接检验了最终单位方向：Web GT1/GT10-hard/soft两半夹角中位24.5°/12.1°/8.5°，Y为27.2°/16.5°；去全体入口共同方向和限制共同正支持后仍保持。行置换也使GT10比GT1稳定，证明其中确有一般平滑因素；真实对应跨半亲和再胜置换，说明并非仅全局收缩。这是受控经验支持，不是方差下降造成最终Recall增益的完整因果证明。

## 3. 方向稳定之后还有两座桥

对单位query，画像得分误差至多为画像方向误差。若精确第3与第4名之间的margin大于相关得分误差之和，精确top3边界不变。改变画像同时重建HNSW时，这一事实不保证近似路由访问序列不变；小图的可检索性仍需实测。已有E115只支持减少扫描邻边，不能写成搜索路径必然缩短。

即使入口的代理得分更准确，有限beam也可能走到相同结果，或因共享候选池改变路径而损伤。多入口不是各自独立搜索结果的并集。GT覆盖、亲和、真实Recall与完整wall需要分别测量。闭式亲和最优不构成Recall或QPS全局最优证明。

## 4. 特权教师有效，仍缺学生所需的校准

E123服务表使用实际GT区域及成员服务响应，特权策略相对默认有正值；它回答的是“额外计算得到的目标信息是否可能有用”。E124预测目标区域并把服务表编译成静态线性打分，却未获得净收益。两阶段线性映射仍属仿射打分，不增加函数类表达能力；给定表S，预测A再乘S与对伪标签AS做相应ridge代数等价。

令真实效用u，服务代理g=AS，便宜评分ĝ=ÂS；a_g和a_hat分别最大化g和ĝ。令r=u−g，则每条query恒有

$$u(a_g)-u(a_{hat}) = [g(a_g)-g(a_{hat})] + [r(a_g)-r(a_{hat})]。$$

第一项是对特权评分的决策遗憾，非负；第二项有正有负。E124从3K到19K时，语义MSE、服务中心化MSE及第一项四格都改善，真实效用仍两格升两格降，双集等K均值下降。固定raw-sum ridge的α/n同时改变，所以这不是只改变样本数的因果实验。

区域服务S_g=E[D|G=g]再按query区域平均，一般不等于E[D|q]。缺少区域在query/rank/搜索预算上的条件充分性，不能称该操作自动Rao–Blackwell化真实效用。完美区域预测也可能精确重现一个有偏服务目标。

对固定动作族，若a_u最大化u、a_hat满足 ĝ(a_hat)≥max_a ĝ(a)−ε_route，标准最大化不等式给出

$$u(a_u)-u(a_{hat}) \le osc_a(u-g) + osc_a(g-\hat{g}) + \varepsilon_{route}。$$

默认动作必须作为一列；osc为同query跨动作极差。第一项是代理偏差，第二项是预测偏差，第三项是近似选择误差。它不是误差来源的可识别因果比例，也不要求三项实际都大；它明确说明仅缩小第二项不能证明总遗憾缩小。g需与u同量纲，不能直接把原始cosine分数当Recall代入并解释数值。

## 5. 为什么“学更强模型”还不是下一方向

E121已检验原路由上层状态，E122已利用动作几何平滑，E119已有强树/TabM与多个损失，E124已有目标语义中间表示。这些失败不证明全部函数类不可学，也没有给在原分支继续调模型的依据。

下一假设至少要补一个已识别缺口：真实目标预算下的服务偏差；廉价线上表示对净收益的可迁移增量信息；或当前真实候选集合与代理目标的结构缺陷。单纯换损失、做蒸馏、加非线性、把819个输出称作双塔，都没有补上该证据。

固定库、query与规则决定全部真实响应。GT“特权”在计算成本意义上成立，不能解释成原query之外的新Shannon信息。廉价状态和有限模型失败不能导出信息论不可能性。

## 6. 性能还需付费信息价值与完整曲线

串行QPS=1/E[T_full]，T_full包括选择、路由、NSG与返回写内存。Recall事后oracle、NDC或旧graph-only效用都不能替代它。高预算下候选优势可能消失，低预算最优入口也可能迁移失败；本轮固定256-query全H诊断就是为这个缺口提供直接观测，不据它重开已停止的E124。

已有E120三点三重复显示召回均值改善，但完整QPS下降；已有E105显示旧开发正值无法在新来源稳定复现。它们共同要求：先冻结信息、动作、目标预算和费用，再做query外简单控制；通过后才付完整原生计时和新来源验证费用。最终接替仍需完整Recall–QPS及不确定性，不能以“理论更漂亮”代替实测。

## 7. 文献关系与论文边界

Banerjee等的方向聚类是归一化均值/球面统计的直接背景；本报告无需未经验证的vMF假设。查询画像、监督路由和图导航与GATE、NGFix及项目既有Fast有前作关系，不能把它们重新命名为新贡献；详见17:00前调研。

Unifying distillation and privileged information的收益分析包含教师、学生误差及学习条件；有用教师不保证可压缩。Risk Bounds and Calibration for a Smart Predict-then-Optimize Method讨论预测误差到决策风险的条件桥接，并不支持“MSE总是不一致”。本地更根本的问题是AS不一定是真实条件效用；改成SPO损失不能自动修复它。

可主张的是：GT10在固定亲和代理上闭式最优，本轮验证了方向稳定性、实际服务信息与学生可实现价值的差距，并提供明确失败边界。尚不能主张十目标数量最优、全部收益由稳定性造成、现有入口空间已耗尽、或本轮发现了更强线上方法。

## 8. 近似监督：目标ID误差与画像方向误差并不等价

保持H和query不变，近似目标只改变权重a。令v=u+Σa_i x_i，v'=v+δ，δ=Σ(a'_i−a_i)x_i；p=unit(v)，将δ分为沿p的分量δ_parallel=p・δ及垂直分量δ_perp=δ−δ_parallel p。如果||v||+δ_parallel>0，则两方向夹角θ满足

```
tan θ = ||δ_perp|| / (||v||+δ_parallel)。
```

这是几何恒等式，不需要误差无偏。更一般的非零向量界是||unit(v')−unit(v)||≤2||δ||/||v||。因此目标ID替换较多仍可能只有小方向变化：可能仍分配给相同hub，或累加扰动主要平行原方向。但这些机制本轮尚未分别量化；不得从小角度倒推误差无偏或标签正确。对少支持、合力弱的画像同样数量的误差可能更危险。

E125保持20K与公式、只换目标来源，实测Web/Y画像夹角中位0.980°/2.082°，完整QPS接近原件；这是具体稳健性信号。Web K1两批分别净损4/4096和6/4096，说明小画像变化仍会影响少量实际搜索。中位角度不控制尾部画像，精确得分margin不控制近似HNSW路径，二者都不构成无损Recall保证。

理论上的下一条可检验预测是：在原训练侧，同等目标ID错误率下，垂直于原画像的累计扰动比单纯标签错误率更能解释方向变化；这条几何解释本身不保证搜索改进。任何据此设计的纠偏应先固定训练侧选择规则与费用，再在未用于选择的query上测实际质量，不能针对本轮新测试的损伤query修补。

当前研究策略也作了对应修正：未通过旧非劣区间不意味着近似监督无效。该版本保留为有质量取舍的低成本候选，历史原门和原结果仍独立保存。

## 9. 近似标签之后的明确估计目标

固定教师/H/温度，精确贡献y_i、近似贡献z_i。在N个训练样本中简单随机无放回取m个补精确GT，经典差值估计为

```
v_hat = u + Σ_i z_i + (N/m)Σ_{i∈S}(y_i−z_i)。
```

对采样设计E[v_hat]=v_exact；设S_residual为有限总体残差协方差，向量均方误差为$N^2(1-m/N)tr(S_{residual})/m$。unit之后不再保证无偏，稀少残差可能使校正更差，更不保证Recall。不能先依补标结果选择教师/温度再直接套用固定目标结论；Web原温度也有精确GT标定费用。

本轮只读训练池核算：按精确合力平方归一化的总和MSE，优于直接近似的解析临界m约3269/8517（Web/Y的16.34%/42.58%）。未据此采样、训练候选或设Recall门；用于衡量额外成本。残差核算与完整条件保留细节。

Prediction-Powered Inference说明均值校正与经典差值估计的关系，附录B含有限总体范围。这里是标准工具在画像总和上的应用，不是ANN新保证。

# 研究判定策略：探索与默认替换分开

2026-09-22按用户“调整旧门一票否决的策略，太严苛了”生效。旧版本的冻结协议、原始结果、门值和当时判定保留，新的研究决策使用本策略。

## 1. 判定目的先于统计门

探索阶段回答是否有值得验证的信号，默认替换阶段回答收益是否足够可靠、适用范围是否清楚。降标签/构建费用、线上速度、召回和理论解释是不同目标；降低构建成本且检索质量接近的版本可以成为独立工程候选，不必先同时胜过全部线上指标。

不再要求每个探索点的置信下界同时过门才能继续。未能证明非劣只能记为“非劣证据不足”；区间包含明显损伤时要如实披露可能风险，但不能等同“损伤已经确立”。同时报告效应量、区间、救回/损伤、实际成本收益、跨点与跨来源一致性。平均值也不能掩盖有实际意义的关键场景退化。

## 2. 三种后续决定

- **保留探索候选**：有具体价值、观测损失较小或不稳定、机制与实现可解释。可做与不确定性直接相关的最小复测；不要求改名或先发明新机制才能复核同一冻结模型。
- **证据不足，暂不替换**：正负范围都合理，当前样本不能支持明确结论。可保留成本/质量取舍，不把它写成算法失败。是否继续取决于预期价值和剩余预算。
- **停止投入某个版本**：可复现的实质损伤、成本明显不可支付、实现不满足必要合同，或继续验证的价值不足。说明具体原因与范围，不能从一个统计边界泛化为整条路线无效。

默认替换仍需在相关工作负载上证明有实际价值，并说明质量/速度/构建成本的取舍。按应用价值选主点和可接受损失，不默认所有点都必须逐个显著，不以多点平均掩盖关键点损伤；证据不足时保留默认和候选并列。

## 3. 有限复测而非看到通过才停止

每次追加在新数据读取前记录问题、冻结模型、样本来源/数量、测试点、完整成本、分析方法和截止时间。报告所有结果。固定一组复测可以直接用预定单点区间，不能拿新95%区间改写旧四点98.75%门。若要合并新旧数据，需同时给出两批独立结果，披露旧批已曝光且复测由旧结果触发；不能将合并后显著称为独立确认。不能逐批追加直到过线、在测试结果上调参、只挑有利点，或把旧测试重新称为未见数据。

## 4. 本次E125如何适用

旧E125中12点均值/QPS容差通过，20K画像目标费用显著下降；Web K1/L1000旧批3条救回、7条损伤，少命中4/4096，即−0.097656pp；98.75%区间下界−0.292969pp没有达到预设−0.25pp。旧“STOP”记录准确描述当时协议，但据此直接终止探索偏保守。

当前定位改为**低成本GT10候选，有待独立复测确认质量取舍**。用户已授权冻结模型的Web单组新查询复测，不重新训练、不调教师L、不改原数据结果。本次结论由实际复测证据更新；没有自动部署或无期限扩大实验。

# 特权教师与决策代理：一手文献适用范围

2026-09-22晚间核对原文方法和条件。以下不产生新的训练路线。

Lopez-Paz等，ICLR2016，Unifying distillation and privileged information：核对§3、§4.1和§4.3。论文区分重建特权表示与学习教师软标签；其优势分析显式含教师误差、学生拟合教师的误差和学习速率假设。因此有用教师并不自动保证学生能低成本继承收益。E123/E124符合这一警示，但本地服务表并非该论文实验，不能借文献证明此处更大模型会成功。传统蒸馏/特权学习不是本项目新颖性。

Liu、Grigas，NeurIPS2021，Risk Bounds and Calibration for a Smart Predict-then-Optimize Method：核对§2–3及Theorem2.1。它将预测误差与实际决策损失区分，并给定分布/几何条件下的校准界；所引Fisher一致性定理需要条件连续、关于均值中心对称、唯一最优等前件，不能未经验证套到当前离散确定性搜索标签。论文也明确最小二乘在真实成本预测问题有风险传递结果，不应把本地有限样本失败写成MSE普遍不一致。当前更关键的是E124拟合的服务代理本身不同于真实效用；改成SPO名称不会自动修复标签偏差。

Elmachtoub、Grigas，Smart Predict, then Optimize原文的摘要与以上原文给出直接决策损失的前作。项目E29结构化margin、E32精确期望收益、E119多损失与强模型已存在；本轮不以换损失重启。新的只读分解和反例见语义决策几何。