GT10：OOD 入口选择方法与实验总结

整理日期：2026-09-17。研究定位：**面向查询与库向量分布不一致的 OOD 检索，在固定底层 NSG 上选择更有效的真实入口。**

一、当前保留的方法（2026-09-10，E24）

流程：QGT 选择真实入口 → GT10 构造查询画像 → Micro-HNSW 检索画像 → 从三个真实入口执行原 NSG 搜索。

配置	WebVid	Yandex
保留版本	GT10-soft-t1	GT10-hard
真实入口数 / 向量维度	815 / 512	821 / 200
画像训练查询 / GT 目标数	20,000 条 / 每条前 10 个	20,000 条 / 每条前 10 个
GT 目标归属	softmax，温度约 0.0162	每个目标归给最相近入口
在线输出	3 个真实入口	3 个真实入口

① **先选择真实入口集合。**用独立 5K 查询及其 exact GT100，将查询归一化后做球面 k-means。每簇优先查看离中心最近的查询，从其 GT100 中按名次选择未重复的真实库节点；不足时继续查看簇内查询。最终得到 815/821 个真实 ID。聚类中心只用于选点，后续画像不沿用这一步的聚类分组。

② **用 GT10 决定查询向各入口的分配。**记查询为 q_i、第 t 个 GT 目标为 g_{it}、入口为 h_j。先计算目标向量与入口向量的余弦相似度 $s_{itj} = \mathrm{unit}(x_{g_{it}}) \cdot \mathrm{unit}(x_{h_j})$。hard 将每个目标分给分数最高的入口；soft 将该目标按 $b_{itj} = \exp(s_{itj}/T) / \Sigma_\ell \exp(s_{it\ell}/T)$ 分给全部入口，再对十个目标平均：$a_{ij} = (1/10)\ \Sigma_t\ b_{itj}$。例如 hard 下，十个目标有 6/3/1 个分别归给 A/B/C，则查询对三个画像的权重为 0.6/0.3/0.1。**“硬”指每个目标只归一个入口，一条查询仍可贡献给多个画像；每条查询总权重为 1。**

③ **聚合查询向量，生成入口画像。**对入口 j 计算 $p_j = \mathrm{unit}(\mathrm{unit}(x_{h_j}) + \Sigma_i\ a_{ij} \cdot \mathrm{unit}(q_i))$。入口的原始单位向量提供权重为 1 的先验；按归属权重累加训练查询的单位向量，再归一化。无查询支持时保持原入口方向。**GT 目标向量负责计算权重，实际累加的是查询向量。**因此画像描述哪些查询适合进入该节点，画像与真实入口 ID 一一绑定。

④ **冻结 hard/soft 和温度。**历史 E24 比较 GT1/GT10 的 hard 与三档 soft，共八个候选；温度尺度取训练 GT1 目标对入口最高/次高余弦差的中位数，再乘 0.25/1/4。以开发集 1,024 条查询、L128 的真实搜索命中优先、距离次数其次选型，冻结 WebVid soft-t1、Yandex hard。t1 是档位编号，实际温度约 0.0162；此次重测没有按测试结果重新选型。

⑤ **在线仅检索小图并映射真实入口。**在画像上建立 Micro-HNSW（M=16、efConstruction=200），新查询以 efSearch=10 找到三个画像，将对应的三个不同真实 ID 交给原 NSG。查询侧保持原向量，底层搜索仍使用原内积指标；soft 分配已固化在画像中，线上无需 GT、softmax 或神经网络前向。

GT10 的 OOD 针对性来自“训练查询 → 真实目标 → 库中入口”的关联监督。它有闭式画像解，当前保留版本无需 MLP/RL；但几何归属仍是搜索效用的代理，未直接优化三个入口的联合收益。 画像聚合使用 20K 查询，与本次选型/审计片段不重叠；相关数据存在其他历史使用。完整离线成本还包括 exact GT、QGT 选入口与小图构建，尚无重新计量的从零总耗时。

二、当前效果（2026-09-17，优化后五集重测）

NSG、GT10、GATE 使用同一优化内核；HNSW 同轮计时。正式评测同机单线程、包含路由，每个配置重复三轮。下表采用达到 90% Recall 门槛的最快实测预算，各方法实际 Recall 不完全相同。

数据集及默认	指标	GT10 实际 Recall	GT10 QPS	NSG QPS	QPS 变化
WebVid · soft	Recall@1	90.7500%	520.79	416.68	+24.99%
WebVid · soft	Recall@100	90.6868%	340.46	337.80	+0.79%
Yandex · hard	Recall@1	91.0500%	2406.16	2194.80	+9.63%
Yandex · hard	Recall@100	90.9805%	1241.64	1160.90	+6.96%

完整曲线中，WebVid/Yandex 收益较清楚，但 WebVid 高召回的 Recall@100 提速已很小；Deep/SIFT 有较小到中等收益，GIST 相对 NSG 无稳定优势。当前结果支持 GT10 有实际价值，未支持全条件最优。 零命中也有局部改善：K100、L100 时，WebVid 的 NSG/soft 失败率为 1.03%/0.17%，Yandex 的 NSG/hard 为 1.93%/0.74%。这是同预算比较，完整失败曲线见文末。

三、GT10 之后做过的改进（2026-09-10—09-14，E25—E95）

本节数字为历史 Recall@10，pp 表示百分点；L 为搜索预算。后续新实验只测 Recall@1/100，GT10 名称中的 10 仍指训练目标数。

09-10｜门控与画像混合（E25—E26）

- 查询门控选择 GT1/GT10：少量召回改善被额外路由成本抵消。直接混合两种画像：多数点削弱原 GT10 收益。

09-11｜机制分析、离线 MLP 与联合教师（E27—E32）

- GT10-hard 的有效样本量中位数由 WebVid 16→67.36、Yandex 22→60.08；打乱 GT 关联后多数结果变差，支持多目标关联有作用，但信息与平滑作用尚未完全分离。
- 训练共享线性变换、小 MLP（d→64→d）和自由残差，离线导出画像、重建小 HNSW；线上无需运行网络。每条查询取 8 个候选，枚举 56 个三入口组合，以真实搜索命中、距离次数产生教师。WebVid MLP 在 L400 相对 hard 提高 0.240 pp、QPS 约持平；低预算和 Yandex 未稳定改善。
- 继续试过无收益时保留原入口、多组等效教师、交叉熵/margin、延长训练和直接优化组合期望 Recall。训练改善未转化为稳定最终优势；直接组合评分还增加在线成本。

09-11｜小路由图删边 RL、在线 MLP 换点（E33—E36）

- RL 学习小 HNSW 边的保留概率，部署静态图：路由距离次数下降约 18%～19%，完整 QPS 未稳定改善。这些修改作用于入口路由小图。
- 在线 MLP 从 8 个候选中替换三入口或停止，最多三步，并做精确梯度对照。audit512、L128 上，WebVid Recall −0.4688 pp/QPS −9.32%，Yandex +0.3906 pp/−8.30%。即使早停也先评分全部 56 个集合；距离计算次数未计入模型运算，因此距离次数少不保证速度快。

三、GT10 改进实验（续）

09-12｜离线画像 RL、反馈与更新机制（E37—E59）

- 离线扰动画像→重建小 HNSW→真实搜索奖励，比较 RL 与成对扰动 ES；从整套画像共享变换改为一次只动一个画像，仍未稳定改善。小 batch 容易漏掉有效动作，改用完整训练池反馈与完整三入口的精确缓存。已有净正候选时，RL 更新后的均值模型仍不改变训练池命中的比例为 WebVid 85.98%、Yandex 95.88%。
- 非 RL 贪心提交的 WebVid 两 seed 在 monitor 上提高 0.3125/0.2051 pp，Yandex 一正一负；RL 方向配合真实步长接受，也只得到局部收益。
- 试过只学小图构建向量、建图后恢复原画像评分。每集扩展至 19 个候选并冻结选型后，最终两集×五预算的 Recall 均略低于原默认，QPS 差异在重复计时范围内。

09-13｜目标重权、多画像和小图局部修复（E60—E94）

- 固定 RL 动作在另一来源查询上做迁移支持检查，两集同时满足训练目标和辅助支持的状态均为 0/40。遗漏目标/失败查询重权有训练收益，也损伤原本正确的查询。
- 每个入口增加两个子画像，小图检索后去重成三入口；试过去重精简、搜索加宽、子画像收缩和目标分组。Yandex 精简版开发 L128 为 +0.2881 pp/QPS −0.96%，WebVid 未获同样改善。
- 再试小路由图补边、恢复父画像及组合修复。冻结最终比较中，WebVid 组合在 L128 比精简版高 0.270 pp，但比原 soft 低 0.385 pp；Yandex 精简版比 hard 高 0.070 pp，高预算又有损伤。

09-14｜查询统计构图与分支停止（E95）

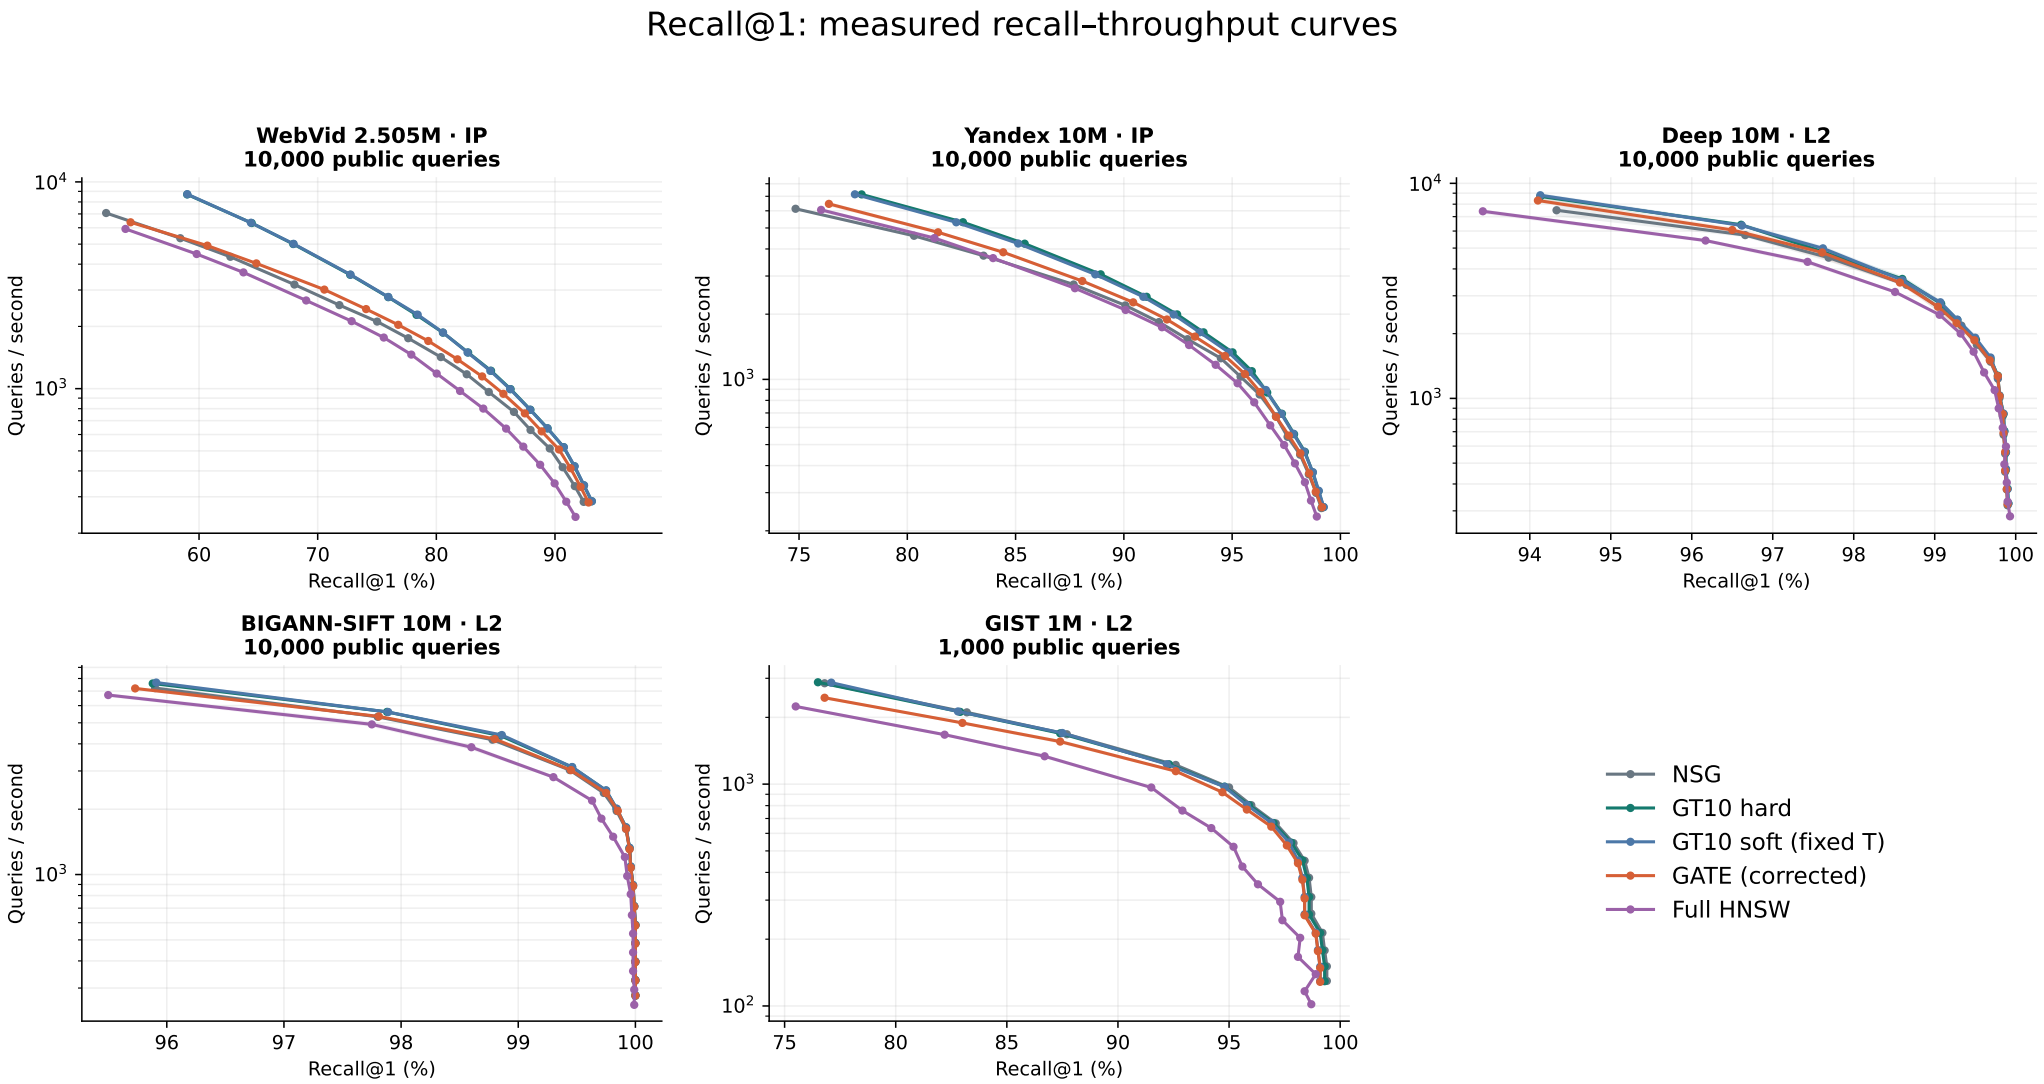
- 用查询二阶矩的完整矩阵/对角尺度生成小图构建向量，建图后恢复原画像评分。两集×两种构造×两预算共八个开发点，Recall 全降、零命中全增，未继续测 QPS。停止当前固定入口集合下的画像/小图增强分支。MLP、RL、表示改造均已实际验证；局部进展保留，尚无稳定最终替代方案。

四、NSG 实现优化与统一重测（2026-09-16—09-17，E98—E103）

- **09-16，成本诊断：**WebVid 路由仅占约 0.5% 耗时；距离/访存等待、邻接检查、visited 和候选池维护占主要开销。NSG 检查的邻接槽约 71.82% 为空，因此距离计算次数少仍可能更慢。
- **09-16，第一轮优化：**提前预取邻居向量和 visited，减少候选池空槽复制，同时保留原等距排序与重复处理。WebVid 四预算、四种入口策略的 QPS 提升 10.51%～13.53%；五集输出、距离、入口及逐查询距离计数一致。
- **09-16，进一步优化：**用有效邻接长度跳过连续尾部空槽，采用四个邻居一组的距离计算与预取组织（span+batch4）；补测原生 Faiss NSG，对照其不同初始化语义。统一应用于 NSG、GT10-hard/soft、GATE 后，NSG 自身四个预算的 QPS 再提高 18.58%～27.28%（相对同轮第一版优化内核）。
- **09-17，完整重测：**WebVid、Yandex、Deep、BIGANN-SIFT、GIST，五方法×两种 K×16 预算，共 800 配置、2,400 轮正式计时，约 13 小时。模型、底图和返回结果保持，所有方法采用一致条件；新 QPS 与失败率完整图如下。
- **归因与落地：**公共内核提速属于实现收益；GT10 的方法收益按相同新内核对比 NSG。优化保持底图边和入口策略，不是改底图算法；span+batch4 当前用于独立评测入口，生产代码仍为第一轮优化版本。

图 1 · Recall@1 与 QPS

完整重测 · 五个数据集 · 2026-09-17

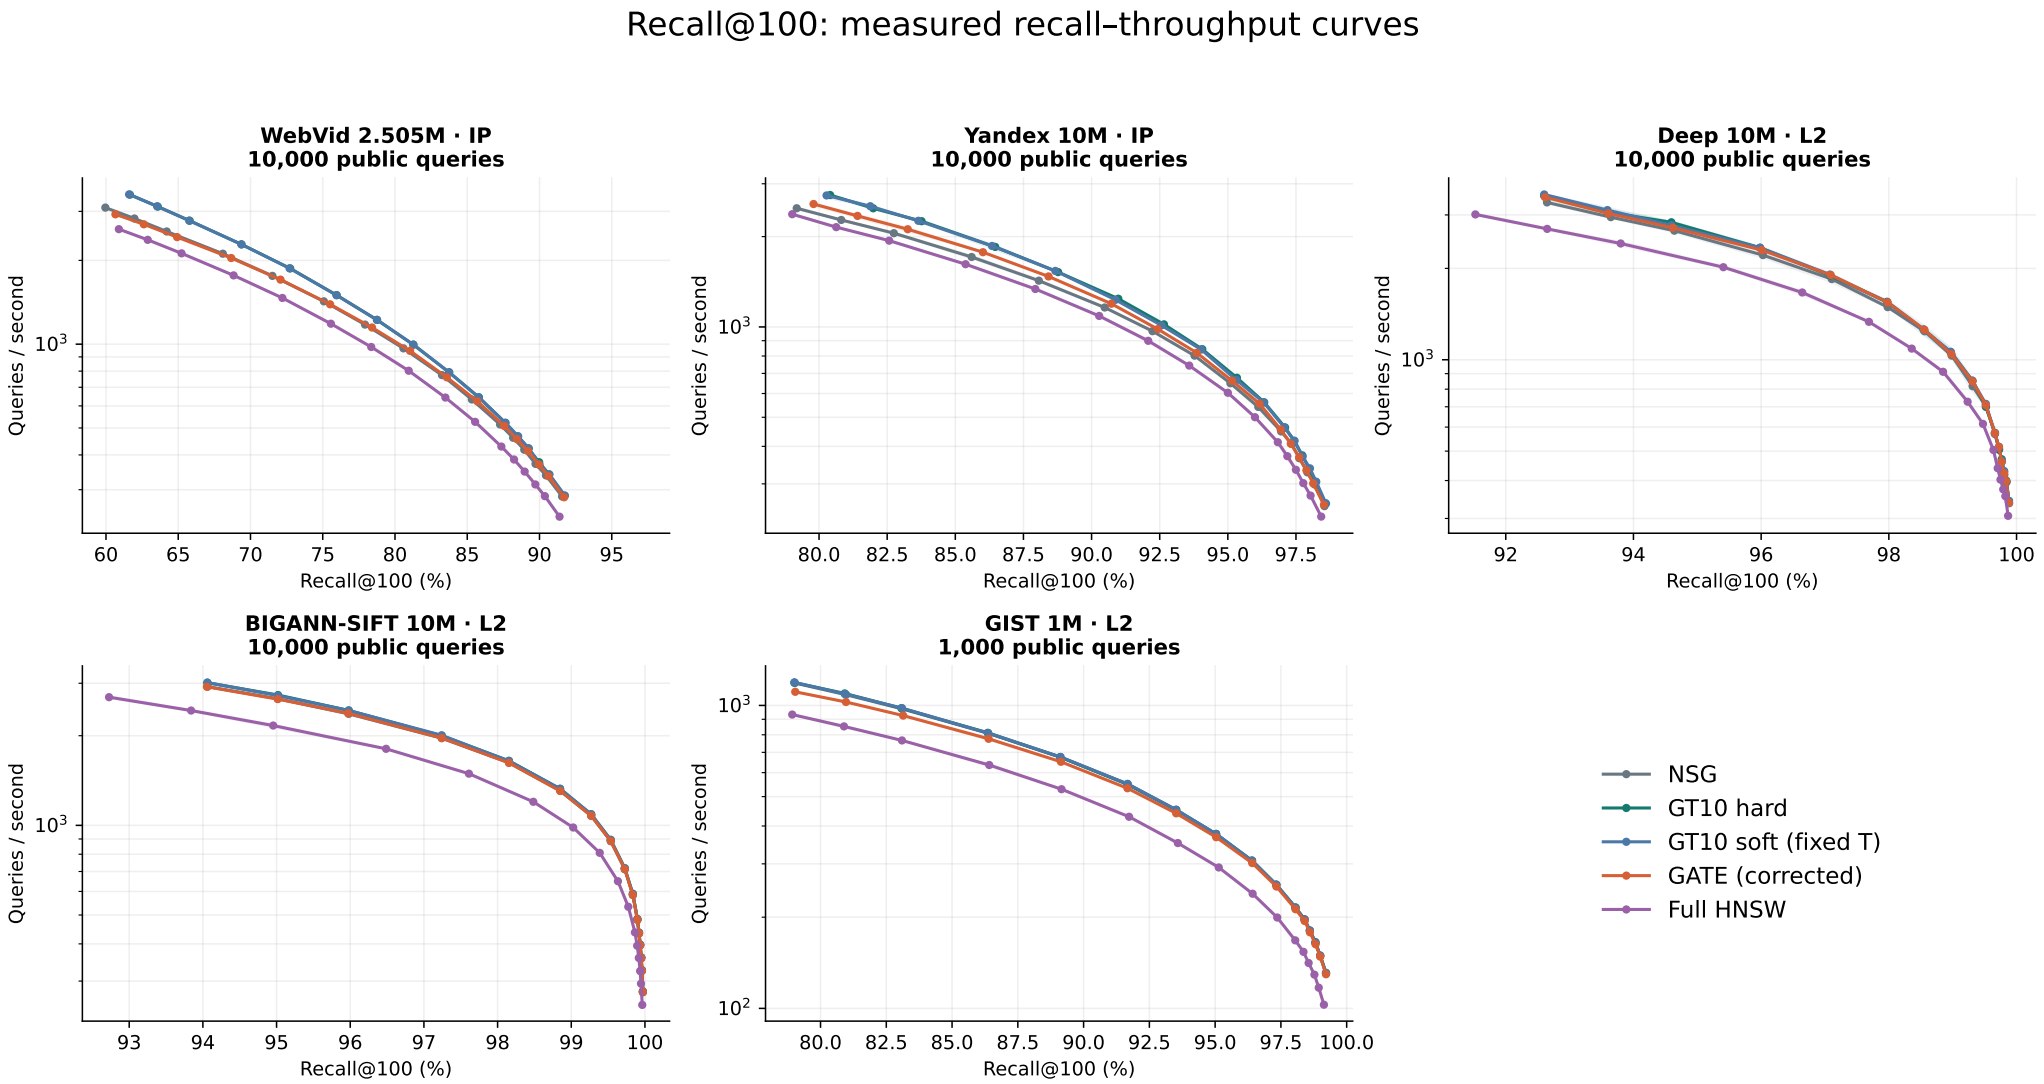


Five datasets; LAION excluded. One CPU thread, 16 budgets, 3 timing repeats. Shared optimized NSG kernel; frozen models; same-run HNSW.

每条曲线包含全部 16 档实测预算，QPS 为三轮均值，阴影表示最小—最大范围。NSG、GT10 和 GATE 共用优化内核，完整 HNSW 同轮计时；所有方法均为单线程。

图 2 · Recall@100 与 QPS

完整重测 · 五个数据集 · 2026-09-17

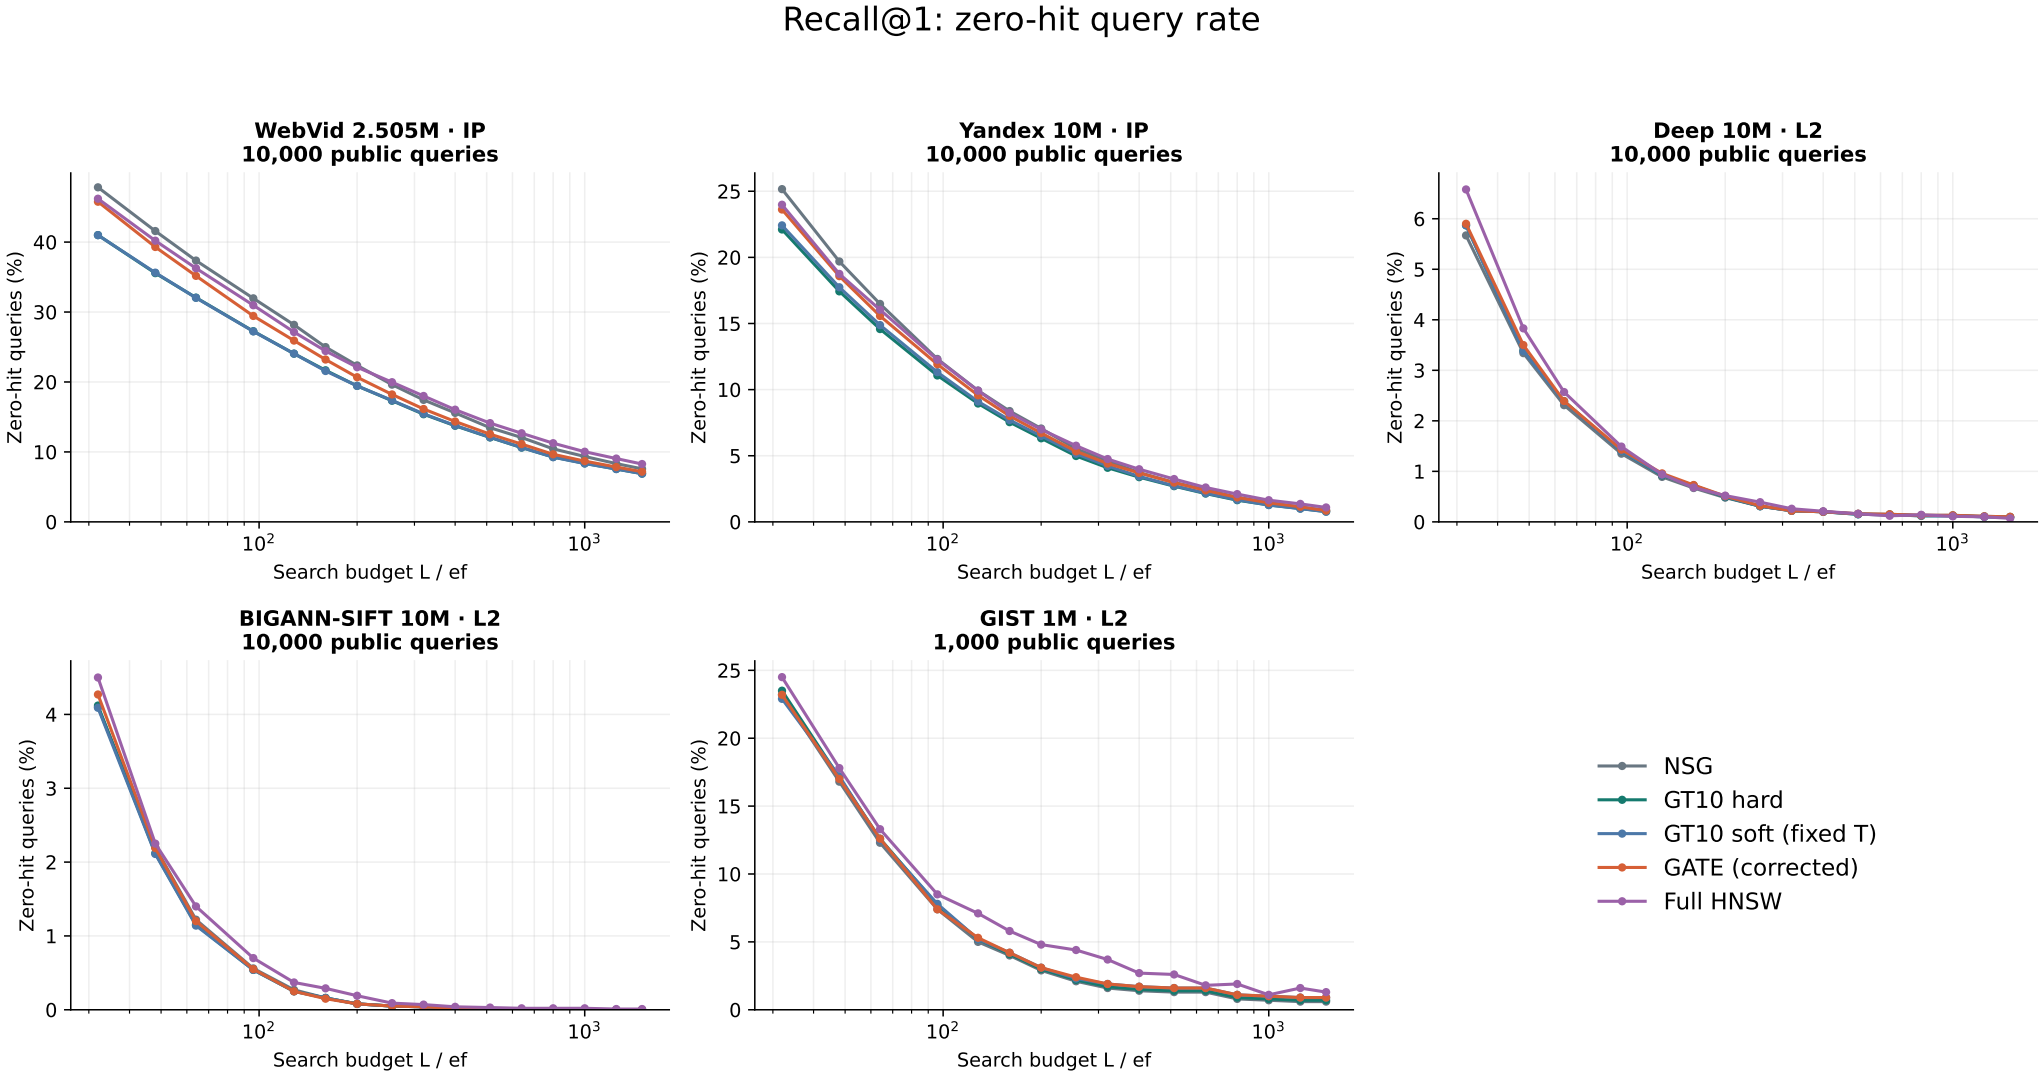


Five datasets; LAION excluded. One CPU thread, 16 budgets, 3 timing repeats. Shared optimized NSG kernel; frozen models; same-run HNSW.

横轴为 Recall@100，纵轴为 QPS（对数轴）。计时包含路由与搜索；各方法均展示完整曲线。高召回区间的小幅速度差需结合三轮计时范围判断。

图 3 · K=1 的失败查询率

失败定义 · 未找到真实最近邻

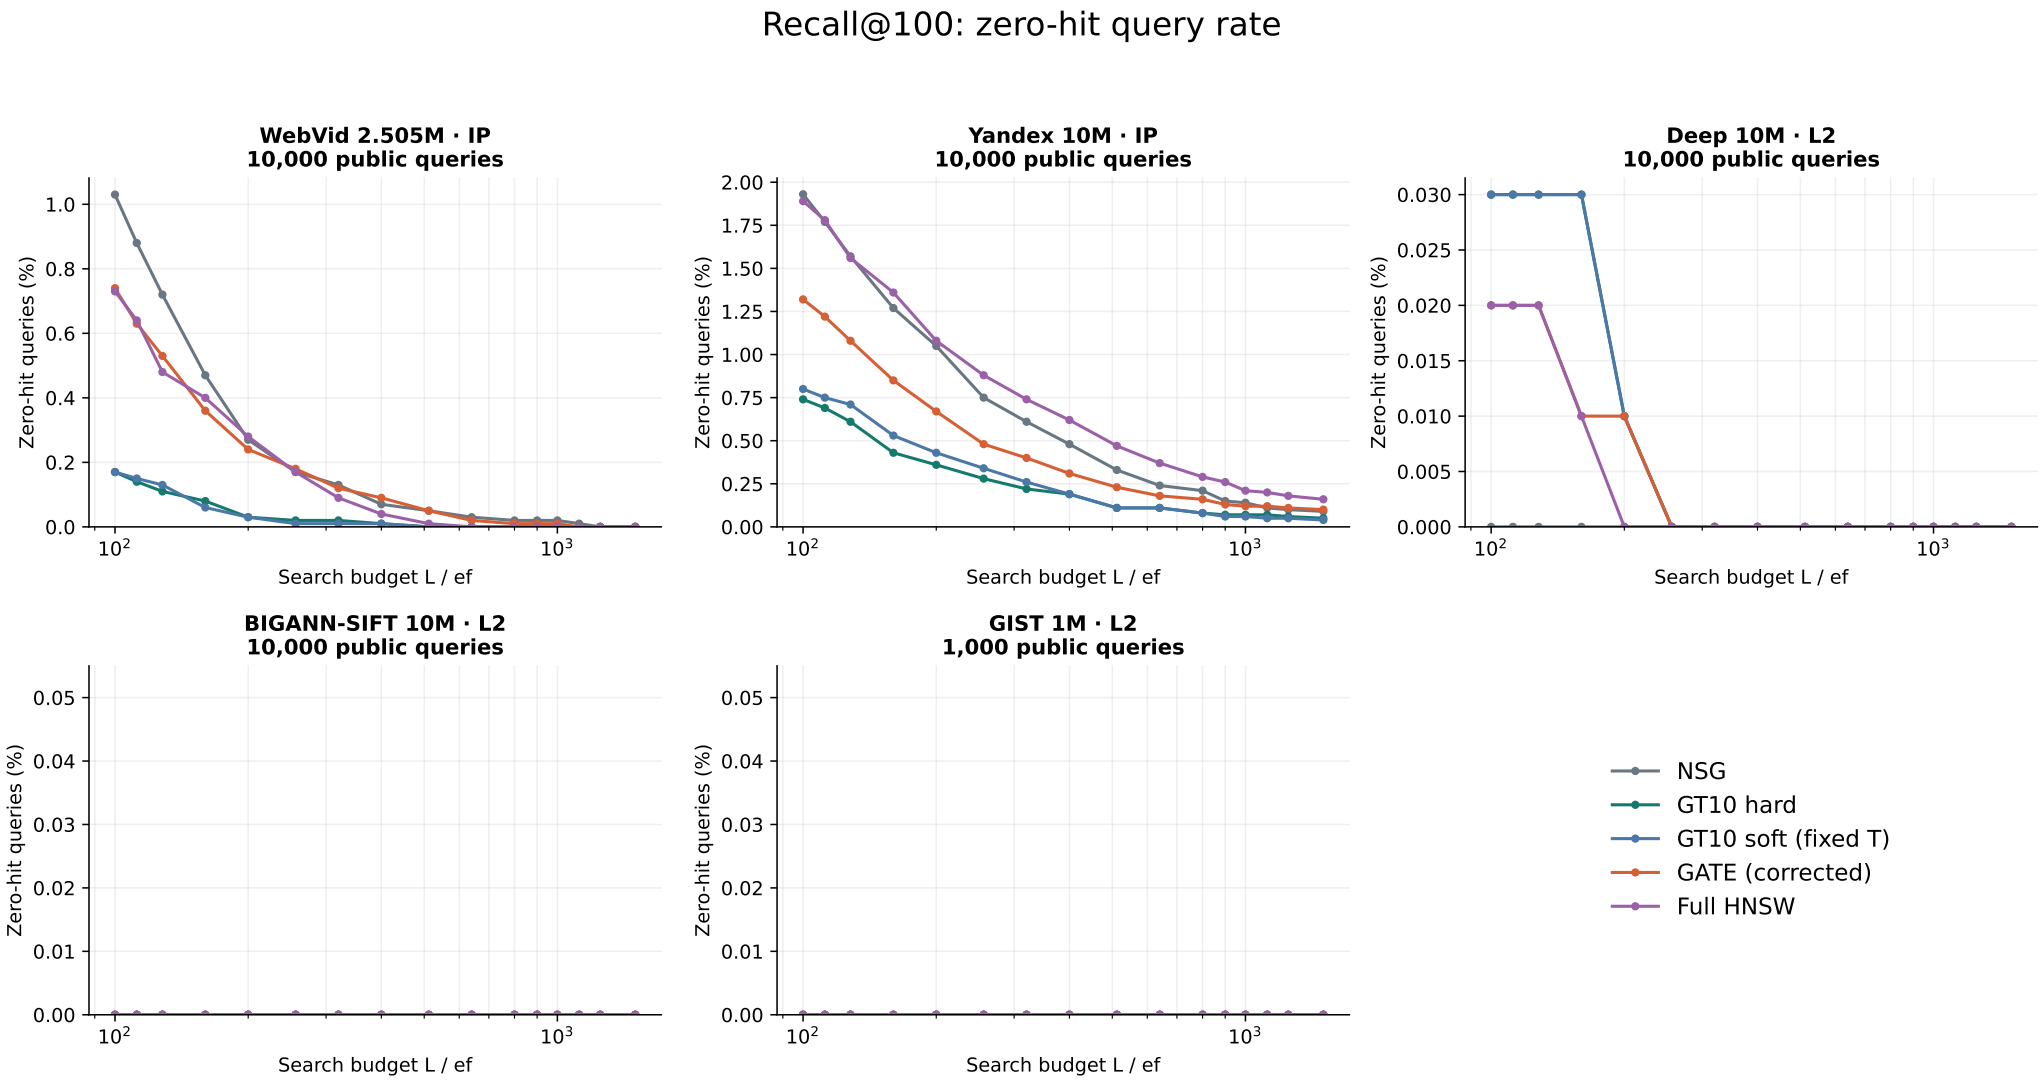


Five datasets; LAION excluded. One CPU thread, 16 budgets, 3 timing repeats. Shared optimized NSG kernel; frozen models; same-run HNSW.

失败率为返回 top-1 未命中 exact GT top-1 的查询比例，即 1−Recall@1。横轴为搜索预算 L/ef（对数轴），纵轴越低越好；相同 L/ef 不表示不同方法工作量相同。

图 4 · K=100 的失败查询率

失败定义 · 返回的前百结果与真实前百近邻零交集



Five datasets; LAION excluded. One CPU thread, 16 budgets, 3 timing repeats. Shared optimized NSG kernel; frozen models; same-run HNSW.

失败率为返回 top-100 与 exact GT top-100 交集为空的查询比例。SIFT/GIST 本轮各预算均为零失败；这表示至少命中一个真实前百近邻，不代表 Recall@100 达到 100%。